

ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ

ΣΧΟΛΗ ΤΕΧΝΟΛΟΓΙΩΝ ΠΛΗΡΟΦΟΡΙΚΗΣ ΚΑΙ ΕΠΙΚΟΙΝΩΝΙΩΝ

ΤΜΗΜΑ ΠΛΗΡΟΦΟΡΙΚΗΣ

Εργασία Μαθήματος
«Επιστημονική Συγγραφή στην Εκπαίδευση»

Τίτλος Επιλεγμένου Θέματος	Συγκριτική Μελέτη Έμπειρων Συστημάτων (Expert Systems) και Συστημάτων Μηχανικής Μάθησης (Machine Learning Systems): Ομοιότητες, Διαφορές και Εφαρμογές (Κ.Λ.)
Ονοματεπώνυμο Φοιτητή	ΚΑΝΑΚΗΣ ΠΕΡΙΚΛΗΣ
Πατρώνυμο	ΔΗΜΗΤΡΙΟΣ
Αριθμός Μητρώου	Π23062

Ημερομηνία Παράδοσης: 02/2026

Copyright ©

Απαγορεύεται η αντιγραφή, αποθήκευση και διανομή της παρούσας εργασίας, εξ ολοκλήρου ή τμήματος αυτής, για εμπορικό σκοπό. Επιτρέπεται η ανατύπωση, αποθήκευση και διανομή για σκοπό μη κερδοσκοπικό, εκπαιδευτικής ή ερευνητικής φύσης, υπό την προϋπόθεση να αναφέρεται η πηγή προέλευσης και να διατηρείται το παρόν μήνυμα.

Οι απόψεις και τα συμπεράσματα που περιέχονται σε αυτό το έγγραφο εκφράζουν αποκλειστικά τον συγγραφέα και δεν αντιπροσωπεύουν τις επίσημες θέσεις του Πανεπιστημίου Πειραιώς.

Ως συγγραφέας της παρούσας εργασίας δηλώνω πως η παρούσα εργασία δεν αποτελεί προϊόν λογοκλοπής και δεν περιέχει υλικό από μη αναφερόμενες πηγές.

Περίληψη

Η παρούσα εργασία εξετάζει συγκριτικά δύο θεμελιώδεις προσεγγίσεις της Τεχνητής Νοημοσύνης: τα Έμπειρα Συστήματα (Expert Systems) και τα Συστήματα Μηχανικής Μάθησης (Machine Learning Systems). Σκοπός της μελέτης είναι η ανάλυση των αρχιτεκτονικών χαρακτηριστικών, της φιλοσοφίας αναπαράστασης γνώσης και των μηχανισμών λήψης αποφάσεων που διέπουν κάθε προσέγγιση, καθώς και η αξιολόγηση των πλεονεκτημάτων, των περιορισμών και των σύγχρονων εφαρμογών τους.

Για την εκπόνηση της εργασίας ακολουθήθηκε συστηματική βιβλιογραφική ανασκόπηση σε διεθνώς αναγνωρισμένες επιστημονικές βάσεις δεδομένων, με έμφαση σε δημοσιεύσεις της περιόδου 2020–2025. Η ανάλυση επικεντρώθηκε σε ζητήματα ερμηνευσιμότητας, υπολογιστικών απαιτήσεων, διαδικασιών εκπαίδευσης, συντήρησης και κανονιστικής συμμόρφωσης. Παράλληλα, εξετάστηκαν σύγχρονες υβριδικές προσεγγίσεις που συνδυάζουν συμβολικές τεχνικές με τεχνικές βασισμένες σε δεδομένα.

Τα ευρήματα καταδεικνύουν ότι τα Έμπειρα Συστήματα υπερέχουν ως προς τη διαφάνεια και την προβλεψιμότητα, ενώ τα Συστήματα Μηχανικής Μάθησης εμφανίζουν υψηλότερη προσαρμοστικότητα και ικανότητα επεξεργασίας μεγάλων και σύνθετων δεδομένων. Συμπερασματικά, η επιλογή μεταξύ των δύο τεχνολογιών εξαρτάται από το είδος της εφαρμογής, το επίπεδο ρίσκου και τις απαιτήσεις διαφάνειας, ενώ οι υβριδικές λύσεις αποτελούν μία πολλά υποσχόμενη κατεύθυνση για μελλοντικές εφαρμογές.

Λέξεις Κλειδιά: Έμπειρα Συστήματα, Μηχανική Μάθηση, Ερμηνευσιμότητα, Υβριδικά Συστήματα, Συστήματα Υποστήριξης Αποφάσεων.

Abstract

This study provides a comparative analysis of two fundamental approaches in Artificial Intelligence: Expert Systems and Machine Learning Systems. The aim of the research is to examine their architectural principles, knowledge representation mechanisms, and decision-making processes, as well as to evaluate their advantages, limitations, and contemporary applications.

A systematic literature review was conducted using internationally recognized scientific databases, focusing primarily on publications from 2020 to 2025. The analysis addressed issues related to interpretability, computational requirements, training procedures, system maintenance, and regulatory compliance. In addition, modern hybrid approaches combining symbolic reasoning with data-driven learning techniques were examined.

The findings indicate that Expert Systems offer higher transparency and predictability due to their rule-based structure, whereas Machine Learning Systems demonstrate greater adaptability and capability to process large and complex datasets. The study concludes that the selection between the two technologies depends on the application domain, risk level, data availability, and transparency requirements. Hybrid approaches emerge as a promising direction for achieving a balance between performance and explainability in intelligent systems.

Keywords: Expert Systems, Machine Learning, Interpretability, Hybrid Systems, Decision Support Systems

Πίνακας Περιεχομένων

Copyright ©..... i
Περίληψη iii
Abstract iii
Πίνακας Περιεχομένων iv
Κατάλογος Εικόνων v
Κατάλογος Πινάκων vi
Κατάλογος Διαγραμμάτων vii
1 Εισαγωγή 1
2 Μεθοδολογία 2
3 Ερευνητικοί Σκοποί 2
4 Υπόβαθρο και αποτελέσματα μέχρι σήμερα 3
4.1 Έμπειρα Συστήματα (Expert Systems) 3
4.1.1 Ορισμός και ιστορική αναδρομή 3
4.1.2 Αρχιτεκτονική και λειτουργία 3
4.1.3 Πλεονεκτήματα και μειονεκτήματα 4
4.1.4 Εφαρμογές των Έμπειρων Συστημάτων 5
4.2 Συστήματα Μηχανικής Μάθησης (Machine Learning Systems) 7
4.2.1 Βασικές έννοιες και κατηγορίες 7
4.2.2 Διαδικασία εκπαίδευσης μοντέλων 7
4.2.3 Πλεονεκτήματα και μειονεκτήματα 8
4.2.4 Εφαρμογές της Μηχανικής Μάθησης 9
4.3 Συγκριτική Ανάλυση και Εφαρμογές 10
4.3.1 Ομοιότητες 10
4.3.2 Διαφορές 11
4.3.3 Πίνακας σύγκρισης 11
4.3.4 Σύγχρονες υβριδικές προσεγγίσεις 12
4.3.5 Περιορισμοί και προκλήσεις σε δυναμικά περιβάλλοντα 12
5 Υπολογιστικές απαιτήσεις και πρακτικοί περιορισμοί 13
5.1 Απαιτήσεις δεδομένων και εκπαίδευσης 13
5.2 Κατανάλωση πόρων και υποδομές 13
5.2.1 Υπολογιστική ισχύς και χρόνος εκπαίδευσης 13
5.2.2 Κατανάλωση ενέργειας και λειτουργικό κόστος 14
5.2.3 Συντήρηση, τεχνικό χρέος και αξιοπιστία 16
5.3 Σύγχρονες τάσεις και μελλοντικές κατευθύνσεις 16
5.3.1 Υβριδικά συστήματα και συνδυαστικές προσεγγίσεις 16
5.3.2 Ερμηνευσιμότητα και αξιοπιστία στα σύγχρονα συστήματα 17
5.3.3 Κριτήρια επιλογής μεταξύ Έμπειρων Συστημάτων και Μηχανικής Μάθησης 17
5.4 Ρυθμιστικά και Ηθικά Ζητήματα στην Τεχνητή Νοημοσύνη 18
5.4.1 Ζητήματα Ηθικής και Υπευθυνότητας 18
5.4.2 Επιπτώσεις στην επιλογή τεχνολογίας 19
Αποτελέσματα και Ανάλυση 20
Βιβλιογραφία 21

Κατάλογος Εικόνων

Εικόνα 4.1 Δέντρο αποφάσεων του έμπειρου συστήματος για την αναγνώριση μαθησιακών δυσκολιών 6
Εικόνα 4.2 Γενική δομή ενός SME application 6
Εικόνα 4.3 Πλεονέκτημα και Μειονεκτήματα 8
Εικόνα 4.4 Εφαρμογή μοντέλων μηχανικής μάθησης για την ανίχνευση κυβερνοαπειλών και την αξιολόγηση απόδοσης..... 9
Εικόνα 4.5 Εξέλιξη του αριθμού δημοσιεύσεων που εφαρμόζουν τεχνικές μηχανικής μάθησης 10
Εικόνα 5.1 Σχηματική αναπαράσταση υποδομής μηχανικής μάθησης σε περιβάλλον cloud, με χρήση κατανεμημένων πόρων για εκπαίδευση και εκτέλεση μοντέλων..... 14

Κατάλογος Πινάκων

Πίνακας 4.1 Σύγκριση βασικών χαρακτηριστικών Έμπειρων Συστημάτων και Μηχανικής Μάθησης..... 11
Πίνακας 5.1 Σύγκριση ενεργειακού και λειτουργικού κόστους μεταξύ Έμπειρων Συστημάτων και Συστημάτων Μηχανικής Μάθησης. 15

Κατάλογος Διαγραμμάτων

Διάγραμμα 4.1 Κατανομή εφαρμογών μηχανικής μάθησης στους τομείς επιχειρήσεων 10

1 Εισαγωγή

Η ραγδαία εξέλιξη της Τεχνητής Νοημοσύνης (AI) τα τελευταία χρόνια έχει οδηγήσει στην ανάπτυξη υπολογιστικών συστημάτων ικανών να υποστηρίζουν ή και να αυτοματοποιούν σύνθετες διαδικασίες λήψης αποφάσεων σε πλήθος εφαρμογών, όπως η ιατρική διάγνωση, τα χρηματοοικονομικά συστήματα, η βιομηχανία και η εκπαίδευση. Στο πλαίσιο αυτό, έχουν αναπτυχθεί διαφορετικές προσεγγίσεις για την αναπαράσταση της γνώσης και την εξαγωγή συμπερασμάτων, με δύο από τις σημαντικότερες κατηγορίες να αποτελούν τα Έμπειρα Συστήματα (Expert Systems) και τα Συστήματα Μηχανικής Μάθησης (Machine Learning Systems).

Τα Έμπειρα Συστήματα αποτέλεσαν μία από τις πρώτες επιτυχημένες εφαρμογές της τεχνητής νοημοσύνης, καθώς βασίζονται στην κωδικοποίηση της γνώσης ειδικών μέσω κανόνων και αλγοριθμικών διαδικασιών εξαγωγής συμπερασμάτων. Μέσω μιας βάσης γνώσης και ενός μηχανισμού εξαγωγής συμπερασμάτων, τα συστήματα αυτά μπορούν να προσομοιώνουν την ανθρώπινη λογική και να παρέχουν επεξηγήσιμες και διαφανείς αποφάσεις, γεγονός που τα καθιστά ιδιαίτερα χρήσιμα σε τομείς όπου απαιτείται αξιοπιστία και ερμηνευσιμότητα.

Αντίθετα, τα Συστήματα Μηχανικής Μάθησης υιοθετούν μια διαφορετική φιλοσοφία, καθώς βασίζονται κυρίως σε δεδομένα και αλγορίθμους εκπαίδευσης για την αυτόματη εξαγωγή προτύπων και γνώσης. Η προσέγγιση αυτή επιτρέπει την επίτευξη υψηλής ακρίβειας και την επεξεργασία μεγάλων όγκων δεδομένων, ωστόσο συχνά συνοδεύεται από μειωμένη διαφάνεια και αυξημένες υπολογιστικές απαιτήσεις.

Η παρούσα εργασία στοχεύει στη συγκριτική μελέτη των Έμπειρων Συστημάτων και των Συστημάτων Μηχανικής Μάθησης, αναλύοντας τις βασικές αρχιτεκτονικές τους αρχές, τα πλεονεκτήματα και τα μειονεκτήματα κάθε προσέγγισης, καθώς και τις σύγχρονες εφαρμογές τους. Μέσα από την ανασκόπηση της πρόσφατης βιβλιογραφίας, επιχειρείται η ανάδειξη των ομοιοτήτων και διαφορών τους, καθώς και η διερεύνηση των περιπτώσεων όπου κάθε τεχνολογία υπερέχει ή μπορεί να συνδυαστεί με την άλλη για την ανάπτυξη υβριδικών συστημάτων.

2 Μεθοδολογία

Για την εκπόνηση της παρούσας βιβλιογραφικής εργασίας ακολουθήθηκε μία συστηματική μεθοδολογική προσέγγιση αναζήτησης, επιλογής και ανάλυσης της σχετικής επιστημονικής βιβλιογραφίας. Στόχος ήταν η συγκέντρωση έγκυρων και πρόσφατων ερευνητικών δημοσιεύσεων που αφορούν τα Έμπειρα Συστήματα (Expert Systems) και τα Συστήματα Μηχανικής Μάθησης (Machine Learning Systems), καθώς και τη συγκριτική αξιολόγηση των δύο προσεγγίσεων.

Η αναζήτηση πραγματοποιήθηκε σε διεθνώς αναγνωρισμένες επιστημονικές βάσεις δεδομένων, όπως οι IEEE, ACM, ScienceDirect, Springer και Google Scholar, οι οποίες παρέχουν πρόσβαση σε επιστημονικά περιοδικά και πρακτικά διεθνών συνεδρίων.

Η επιλογή των πηγών βασίστηκε σε κριτήρια ποιότητας, όπως η ένταξη σε περιοδικά υψηλής κατάταξης (Q1/Q2), η συχνότητα αναφορών (citations) και η συνάφεια με τα ερευνητικά ερωτήματα της μελέτης. Αποκλείστηκαν μη επιστημονικές πηγές και μη τεκμηριωμένα διαδικτυακά άρθρα.

Η επιλογή των άρθρων περιορίστηκε σε δημοσιεύσεις της τελευταίας πενταετίας (2020–2025), ώστε να διασφαλιστεί η επικαιρότητα των πληροφοριών και των τεχνολογικών εξελίξεων. Για την αναζήτηση χρησιμοποιήθηκαν κατάλληλες λέξεις-κλειδιά (keywords) και λογικοί τελεστές, όπως: «expert systems», «rule-based systems», «machine learning systems», «supervised learning», «knowledge-based systems», «comparison», καθώς και συνδυασμοί αυτών με τους τελεστές AND και OR.

Αρχικά συλλέχθηκε ένα ευρύ σύνολο δημοσιεύσεων, από το οποίο αφαιρέθηκαν άρθρα που δεν σχετίζονταν άμεσα με το αντικείμενο της μελέτης ή αφορούσαν υπερβολικά εξειδικευμένες εφαρμογές. Στη συνέχεια επιλέχθηκαν κυρίως άρθρα ανασκόπησης (survey/review papers), καθώς και ερευνητικές εργασίες που παρουσίαζαν συγκριτικές αναλύσεις ή εφαρμογές των δύο τεχνολογιών σε πραγματικά σενάρια. Τελικά, το σύνολο της βιβλιογραφίας που χρησιμοποιήθηκε αποτέλεσε τη βάση για τη θεωρητική ανάλυση, τη σύγκριση και τη σύνθεση των αποτελεσμάτων της παρούσας εργασίας.

3 Ερευνητικοί Σκοποί

Η παρούσα εργασία επιδιώκει να διερευνήσει και να απαντήσει στα ακόλουθα ερευνητικά ερωτήματα:

- Ποιες είναι οι βασικές αρχιτεκτονικές και λειτουργικές αρχές των Έμπειρων Συστημάτων και των Συστημάτων Μηχανικής Μάθησης;
- Ποιες ομοιότητες και ποιες διαφορές παρουσιάζουν οι δύο προσεγγίσεις ως προς τον τρόπο αναπαράστασης της γνώσης και λήψης αποφάσεων;
- Ποια είναι τα βασικά πλεονεκτήματα και μειονεκτήματα κάθε τεχνολογίας;
- Σε ποιους τομείς εφαρμογών υπερέχουν τα Έμπειρα Συστήματα και σε ποιους τα Συστήματα Μηχανικής Μάθησης;
- Είναι εφικτός ο συνδυασμός των δύο προσεγγίσεων σε υβριδικά συστήματα και ποια είναι τα οφέλη μιας τέτοιας ενοποίησης;

4 Υπόβαθρο και αποτελέσματα μέχρι σήμερα

4.1 Έμπειρα Συστήματα (Expert Systems)

4.1.1 Ορισμός και ιστορική αναδρομή

Τα Έμπειρα Συστήματα (Expert Systems) αποτελούν μία από τις πρώτες και πιο χαρακτηριστικές εφαρμογές της Τεχνητής Νοημοσύνης, με βασικό στόχο την προσομοίωση της ανθρώπινης σκέψης και της διαδικασίας λήψης αποφάσεων ενός ειδικού σε ένα συγκεκριμένο γνωστικό πεδίο. Η βασική ιδέα πίσω από τα συστήματα αυτά είναι η αναπαράσταση της εξειδικευμένης γνώσης ενός ανθρώπου–ειδικού σε μορφή κανόνων και η αξιοποίησή της από έναν υπολογιστή για την επίλυση προβλημάτων ή την παροχή συμβουλών.

Σε αντίθεση με άλλες προσεγγίσεις της τεχνητής νοημοσύνης που βασίζονται κυρίως σε δεδομένα, τα έμπειρα συστήματα στηρίζονται σε ρητά διατυπωμένη γνώση, η οποία αποθηκεύεται σε μια βάση γνώσης και αποτελείται συνήθως από κανόνες της μορφής «IF–THEN». Μέσω της εφαρμογής αυτών των κανόνων, το σύστημα είναι σε θέση να εξάγει συμπεράσματα, να προτείνει λύσεις και να αιτιολογεί τις αποφάσεις του, προσεγγίζοντας τον τρόπο σκέψης ενός ανθρώπινου ειδικού. [1]

Η ανάπτυξη των έμπειρων συστημάτων ξεκίνησε ήδη από τη δεκαετία του 1970, όταν η έρευνα στην τεχνητή νοημοσύνη επικεντρώθηκε στη συμβολική αναπαράσταση της γνώσης (symbolic AI). Από τα πρώτα και πιο γνωστά παραδείγματα υπήρξαν συστήματα που χρησιμοποιήθηκαν στην ιατρική διάγνωση και στην επιστημονική ανάλυση, αποδεικνύοντας ότι ένας υπολογιστής μπορούσε να υποστηρίξει αποτελεσματικά σύνθετες διαδικασίες λήψης αποφάσεων. Τα αποτελέσματα αυτά οδήγησαν στην ευρύτερη υιοθέτηση των έμπειρων συστημάτων σε τομείς όπως η ιατρική, η βιομηχανία, τα χρηματοοικονομικά και τα συστήματα υποστήριξης αποφάσεων.

Παρόλο που τα έμπειρα συστήματα παρουσίασαν σημαντική επιτυχία τις πρώτες δεκαετίες ανάπτυξής τους, η ανάγκη για χειροκίνητη καταγραφή της γνώσης και η δυσκολία συντήρησης μεγάλων συνόλων κανόνων περιόρισαν σταδιακά την επεκτασιμότητά τους. Ωστόσο, εξακολουθούν να χρησιμοποιούνται σε περιβάλλοντα όπου απαιτείται διαφάνεια, ερμηνευσιμότητα και σαφής αιτιολόγηση των αποφάσεων, χαρακτηριστικά που συχνά δεν προσφέρονται από πιο σύγχρονες προσεγγίσεις που βασίζονται αποκλειστικά σε δεδομένα.[1]

4.1.2 Αρχιτεκτονική και λειτουργία

Η λειτουργία των Έμπειρων Συστημάτων βασίζεται σε μία σαφώς καθορισμένη και δομημένη αρχιτεκτονική, η οποία επιτρέπει την αναπαράσταση και αξιοποίηση της γνώσης ενός ειδικού με συστηματικό τρόπο. Σε αντίθεση με τις μεθόδους μηχανικής μάθησης που στηρίζονται κυρίως σε δεδομένα και στατιστική βελτιστοποίηση, τα expert systems οργανώνονται γύρω από κανόνες και λογικές διαδικασίες συλλογισμού, προσφέροντας μεγαλύτερη διαφάνεια και δυνατότητα ερμηνείας των αποφάσεων [2].

Ο βασικός πυρήνας ενός έμπειρου συστήματος είναι η βάση γνώσης (knowledge base), όπου αποθηκεύονται γεγονότα και κανόνες της μορφής «IF–THEN». Οι κανόνες αυτοί αποτυπώνουν τη συσσωρευμένη εμπειρία ενός ανθρώπινου ειδικού και λειτουργούν ως δομημένες μονάδες γνώσης. Εκτός από απλούς παραγωγικούς κανόνες, η γνώση μπορεί να οργανώνεται και με άλλες μορφές αναπαράστασης, όπως σημασιολογικά δίκτυα (semantic networks), πλαίσια (frames) ή ιεραρχικές δομές εννοιών, επιτρέποντας πιο σύνθετη και οργανωμένη περιγραφή του προβληματικού πεδίου.

Η βάση γνώσης συνεργάζεται με τον μηχανισμό εξαγωγής συμπερασμάτων (inference engine), ο οποίος αποτελεί το «λογικό κέντρο» του συστήματος. Ο μηχανισμός αυτός επεξεργάζεται τα διαθέσιμα δεδομένα και ενεργοποιεί τους κατάλληλους κανόνες ώστε να παραχθούν συμπεράσματα. Η διαδικασία συλλογισμού πραγματοποιείται συνήθως μέσω τεχνικών όπως η προωθητική αλυσίδωση (forward chaining), όπου το σύστημα ξεκινά από τα διαθέσιμα δεδομένα και οδηγείται σε συμπεράσματα, και η οπισθοδρομική αλυσίδωση (backward chaining), όπου ξεκινά από έναν πιθανό στόχο και εξετάζει αν τα διαθέσιμα δεδομένα τον υποστηρίζουν.

Επιπλέον, πολλά έμπειρα συστήματα διαθέτουν υποσύστημα επεξήγησης (explanation facility), το οποίο επιτρέπει την αιτιολόγηση των παραγόμενων συμπερασμάτων προς τον χρήστη. Η δυνατότητα αυτή ενισχύει την εμπιστοσύνη και καθιστά το σύστημα κατάλληλο για περιβάλλοντα όπου απαιτείται λογοδοσία και διαφάνεια. Συμπληρωματικά, ορισμένες αρχιτεκτονικές περιλαμβάνουν μηχανισμούς απόκτησης γνώσης (knowledge acquisition module), μέσω των οποίων ενημερώνεται ή επεκτείνεται η βάση γνώσης.

Η βιβλιογραφία επισημαίνει ότι η συγκεκριμένη δομημένη αρχιτεκτονική, με σαφή διαχωρισμό μεταξύ γνώσης και μηχανισμού συλλογισμού, καθιστά τα expert systems ιδιαίτερα κατάλληλα για εφαρμογές υποστήριξης αποφάσεων, όπου η ερμηνευσιμότητα, η συνέπεια και η προβλεψιμότητα αποτελούν κρίσιμους παράγοντες [2].

4.1.3 Πλεονεκτήματα και μειονεκτήματα

Τα Έμπειρα Συστήματα παρουσίασαν σημαντική ανάπτυξη κατά τις πρώτες δεκαετίες της Τεχνητής Νοημοσύνης, κυρίως λόγω της ικανότητάς τους να αναπαριστούν ρητά τη γνώση ενός ειδικού και να παρέχουν τεκμηριωμένες αποφάσεις. Ένα από τα βασικότερα πλεονεκτήματα των συστημάτων αυτών είναι η εξήγηση των αποτελεσμάτων τους. Καθώς η λογική λειτουργίας τους βασίζεται σε κανόνες «IF–THEN», κάθε συμπέρασμα μπορεί να εξηγηθεί με σαφήνεια, γεγονός που ενισχύει την εμπιστοσύνη του χρήστη και διευκολύνει τον έλεγχο της διαδικασίας λήψης αποφάσεων. Επιπλέον, δεν απαιτείται μεγάλος όγκος δεδομένων για την εκπαίδευσή τους, αφού η γνώση εισάγεται άμεσα από ειδικούς του πεδίου.

Ένα ακόμη πλεονέκτημα είναι η σταθερότητα και προβλεψιμότητα της συμπεριφοράς τους. Τα expert systems λειτουργούν με προκαθορισμένους κανόνες και συνεπώς παράγουν συνεπή αποτελέσματα για παρόμοιες εισόδους, χαρακτηριστικό που τα καθιστά κατάλληλα για συστήματα υποστήριξης αποφάσεων σε κρίσιμους τομείς, όπως η ιατρική διάγνωση, η βιομηχανική παραγωγή και οι χρηματοοικονομικές εφαρμογές. Η βιβλιογραφία επισημαίνει ότι η δομημένη αρχιτεκτονική τους, με σαφή διαχωρισμό μεταξύ βάσης γνώσης και μηχανισμού συμπερασμού, διευκολύνει την κατανόηση και τη συντήρηση του συστήματος.

Ωστόσο, παρά τα πλεονεκτήματά τους, τα έμπειρα συστήματα παρουσιάζουν και σημαντικούς περιορισμούς. Η διαδικασία απόκτησης και κωδικοποίησης της γνώσης από ανθρώπινους ειδικούς είναι χρονοβόρα και απαιτεί μεγάλη προσπάθεια, φαινόμενο που συχνά αναφέρεται ως «knowledge acquisition bottleneck». Επιπλέον, η διαχείριση μεγάλου αριθμού κανόνων καθιστά δύσκολη τη συντήρηση και την επέκταση του συστήματος, ενώ μικρές αλλαγές μπορεί να επηρεάσουν απρόβλεπτα τη συνολική λειτουργία.

Τέλος, σε αντίθεση με τα σύγχρονα συστήματα μηχανικής μάθησης, τα expert systems δεν διαθέτουν μηχανισμό αυτόματης μάθησης από δεδομένα και δυσκολεύονται να προσαρμοστούν σε νέα ή δυναμικά περιβάλλοντα. Για τον λόγο αυτό, παρότι εξακολουθούν να χρησιμοποιούνται σε εφαρμογές όπου απαιτείται διαφάνεια και έλεγχος, συχνά συνδυάζονται ή αντικαθίστανται από πιο ευέλικτες τεχνικές μάθησης. Οι παρατηρήσεις αυτές επιβεβαιώνονται και από σύγχρονες ανασκοπήσεις της βιβλιογραφίας σχετικά με τα χαρακτηριστικά και τους περιορισμούς των έμπειρων συστημάτων.[3]

4.1.4 Εφαρμογές των Έμπειρων Συστημάτων

Τα Έμπειρα Συστήματα έχουν αξιοποιηθεί εκτενώς σε πληθώρα εφαρμογών υποστήριξης αποφάσεων, ιδιαίτερα σε τομείς όπου απαιτείται η αναπαράσταση εξειδικευμένης γνώσης και η παροχή τεκμηριωμένων προτάσεων. Η βιβλιογραφία παρουσιάζει σημαντικό αριθμό μελετών που καταδεικνύουν τη χρησιμότητά τους σε πραγματικά προβλήματα.

Στον ιατρικό τομέα, τα Έμπειρα Συστήματα έχουν χρησιμοποιηθεί εκτενώς για την ερμηνεία ηλεκτροκαρδιογραφημάτων (ECG) και τη διάγνωση καρδιακών ανωμαλιών. Μια πρόσφατη ανασκόπηση συνοψίζει το σύνολο των ερευνών που έχουν αναπτυχθεί για την υποστήριξη της ερμηνείας και διάγνωσης ECG μέσω συνδυασμού expert systems και decision support systems, επισημαίνοντας ότι τέτοιες προσεγγίσεις ενσωματώνουν κανόνες γνώσης και χαρακτηριστικά που έχουν δοκιμαστεί σε πάνω από 90 μελέτες βάσει των διαθέσιμων δεδομένων. Τα αποτελέσματα που παρουσιάζονται σε αυτό το review καταδεικνύουν πως η χρήση expert systems στην κλινική ερμηνεία ECG μπορεί να συμβάλλει στην ακρίβεια της διάγνωσης και στην αποτελεσματικότερη ανάλυση ηλεκτροκαρδιογραφικών σημάτων, ενώ παράλληλα θέτει τις τρέχουσες προκλήσεις και ανοικτά ζητήματα που χρήζουν περαιτέρω έρευνας.[3]

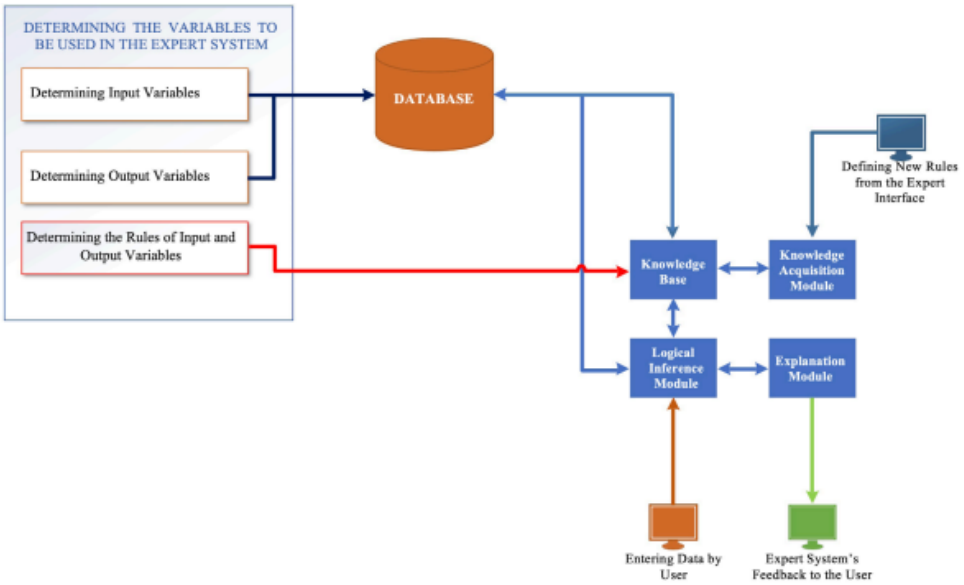
Μία χαρακτηριστική εφαρμογή των Έμπειρων Συστημάτων στον τομέα της εκπαίδευσης παρουσιάζεται στη μελέτη των Supriyadi και Wiliyanto, όπου αναπτύχθηκε ένα πρωτότυπο σύστημα υποστήριξης αποφάσεων για την αναγνώριση ειδικών μαθησιακών δυσκολιών σε παιδιά σχολείων ένταξης. Το σύστημα βασίστηκε σε τεχνικές αναπαράστασης γνώσης και σε σύνολο κανόνων που προέκυψαν από τη συνεργασία με ειδικούς παιδαγωγούς και εκπαιδευτικούς, επιτρέποντας την αξιολόγηση συμπτωμάτων και χαρακτηριστικών συμπεριφοράς των μαθητών. Μέσω του μηχανισμού συμπερασμού, το expert system παρείχε προτάσεις και εκτιμήσεις σχετικά με το είδος και το επίπεδο της μαθησιακής δυσκολίας, λειτουργώντας ως εργαλείο υποστήριξης και όχι ως υποκατάστατο της ανθρώπινης κρίσης. Η εφαρμογή δοκιμάστηκε σε πραγματικό σχολικό περιβάλλον με τη συμμετοχή εκπαιδευτικών, οι οποίοι αξιολόγησαν θετικά τη χρηστικότητα, την αξιοπιστία και την ακρίβεια των αποτελεσμάτων. Τα ευρήματα της μελέτης καταδεικνύουν ότι τα expert systems μπορούν να συμβάλουν ουσιαστικά στη συστηματική και ταχύτερη λήψη αποφάσεων σε σύνθετα παιδαγωγικά προβλήματα, αναδεικνύοντας τη σημασία τους ως εργαλεία υποστήριξης σε κοινωνικά και εκπαιδευτικά πλαίσια.[4]



Εικόνα 4.1 Δέντρο αποφάσεων του έμπειρου συστήματος για την αναγνώριση μαθησιακών δυσκολιών

Πηγή: [4]

Τέλος, στη μελέτη των Er και Güneysu αναπτύχθηκε μια διαδικτυακή εφαρμογή έμπειρου συστήματος με την ονομασία SME Emergency, η οποία στοχεύει στη διαχείριση κεφαλαίου κίνησης μικρομεσαίων επιχειρήσεων. Το σύστημα αξιοποιεί οικονομικά δεδομένα από 283 εταιρείες που συμμετείχαν στη μελέτη και εφαρμόζει κανόνες γνώσης για την εκτίμηση της απόδοσης κεφαλαίου κίνησης, συγκρίνοντας την απόδοση της επιχείρησης με τον μέσο όρο του κλάδου. Ως αποτέλεσμα, παρέχει χρήσιμες πληροφορίες για τη χρηματοοικονομική κατάσταση της εταιρείας, με στόχο την υποστήριξη των επιχειρηματικών αποφάσεων στο πλαίσιο της βελτίωσης των χρηματοοικονομικών πρακτικών. Η συγκεκριμένη εφαρμογή δείχνει πως τα expert systems μπορούν να λειτουργήσουν ως αποτελεσματικό εργαλείο υποστήριξης αποφάσεων σε σύνθετα οικονομικά περιβάλλοντα.[5]



Εικόνα 4.2 Γενική δομή ενός SME application

Πηγη: [5]

4.2 Συστήματα Μηχανικής Μάθησης (Machine Learning Systems)

4.2.1 Βασικές έννοιες και κατηγορίες

Η Μηχανική Μάθηση (Machine Learning – ML) αποτελεί υποπεδίο της Τεχνητής Νοημοσύνης που εστιάζει στην ανάπτυξη αλγορίθμων ικανών να μαθαίνουν αυτόματα από δεδομένα και να βελτιώνουν την απόδοσή τους χωρίς την ανάγκη ρητού προγραμματισμού κανόνων. Σε αντίθεση με τα Έμπειρα Συστήματα, όπου η γνώση ενσωματώνεται χειροκίνητα μέσω κανόνων και λογικών σχέσεων, τα συστήματα μηχανικής μάθησης βασίζονται στη στατιστική ανάλυση και στην ανακάλυψη προτύπων μέσα από μεγάλα σύνολα δεδομένων. Η προσέγγιση αυτή επιτρέπει την προσαρμογή των μοντέλων σε πολύπλοκα και δυναμικά περιβάλλοντα, καθιστώντας τη μηχανική μάθηση ιδιαίτερα αποτελεσματική σε προβλήματα πρόβλεψης, ταξινόμησης και λήψης αποφάσεων [6].

Ανάλογα με τη μορφή των δεδομένων και τον τρόπο εκπαίδευσης, οι τεχνικές μηχανικής μάθησης διακρίνονται σε βασικές κατηγορίες. Η επιβλεπόμενη μάθηση (supervised learning) χρησιμοποιεί συγκεκριμένα δεδομένα και εφαρμόζεται ευρέως σε προβλήματα ταξινόμησης και παλινδρόμησης. Η μη επιβλεπόμενη μάθηση (unsupervised learning) αξιοποιεί μη επισημασμένα δεδομένα με στόχο την ανακάλυψη κρυφών δομών ή ομάδων, όπως στην ομαδοποίηση. Επιπλέον, η ενισχυτική μάθηση (reinforcement learning) επιτρέπει σε έναν πράκτορα να μαθαίνει μέσω αλληλεπίδρασης με το περιβάλλον, λαμβάνοντας αποφάσεις βάσει ανταμοιβών ή ποινών. Οι κατηγορίες αυτές αποτελούν τη βάση της σύγχρονης έρευνας και καλύπτουν ένα ευρύ φάσμα εφαρμογών [5], [6].

4.2.2 Διαδικασία εκπαίδευσης μοντέλων

Η ανάπτυξη ενός συστήματος μηχανικής μάθησης βασίζεται σε μία συστηματική διαδικασία εκπαίδευσης μοντέλων, κατά την οποία τα δεδομένα αξιοποιούνται για την κατασκευή μαθηματικών μοντέλων ικανών να πραγματοποιούν προβλέψεις ή ταξινομήσεις. Σε αντίθεση με τα έμπειρα συστήματα, όπου οι κανόνες ορίζονται ρητά από ειδικούς, στη μηχανική μάθηση το μοντέλο προκύπτει αυτόματα μέσω της ανάλυσης ιστορικών δεδομένων και της βελτιστοποίησης παραμέτρων [6].

Το πρώτο στάδιο της διαδικασίας αφορά τη συλλογή και προεπεξεργασία των δεδομένων. Τα δεδομένα καθαρίζονται από θόρυβο, ελλιπείς τιμές ή ασυνέπειες και μετασχηματίζονται σε κατάλληλη μορφή, ώστε να μπορούν να χρησιμοποιηθούν από τους αλγορίθμους. Στη συνέχεια πραγματοποιείται η επιλογή ή εξαγωγή χαρακτηριστικών (feature engineering), διαδικασία που επηρεάζει καθοριστικά την απόδοση του μοντέλου. Η ποιότητα και η αντιπροσωπευτικότητα των δεδομένων αποτελούν κρίσιμους παράγοντες για την επιτυχία της εκπαίδευσης, καθώς επηρεάζουν άμεσα την ικανότητα του μοντέλου να γενικεύει σε νέα δεδομένα [7].

Ιδιαίτερη σημασία έχει το ζήτημα της μεροληψίας (bias), το οποίο μπορεί να προκύψει από μη ισορροπημένα ή μη αντιπροσωπευτικά σύνολα δεδομένων. Σε τέτοιες περιπτώσεις, το μοντέλο ενδέχεται να εμφανίζει συστηματικά χαμηλότερη απόδοση για συγκεκριμένες κατηγορίες ή πληθυσμιακές ομάδες. Η αναγνώριση και η προσπάθεια μείωσης τέτοιων φαινομένων αποτελούν πλέον αναπόσπαστο μέρος της διαδικασίας ανάπτυξης, ιδιαίτερα σε εφαρμογές με υψηλές κοινωνικές ή οικονομικές επιπτώσεις.

Ακολουθεί το στάδιο της εκπαίδευσης (training), κατά το οποίο το μοντέλο προσαρμόζει τις εσωτερικές του παραμέτρους ώστε να ελαχιστοποιήσει το σφάλμα πρόβλεψης. Συνήθως τα δεδομένα χωρίζονται σε σύνολα εκπαίδευσης, επικύρωσης (validation) και δοκιμής (testing), ώστε να αξιολογηθεί η ικανότητα γενίκευσης του μοντέλου σε άγνωστα δεδομένα. Η προσέγγιση αυτή συμβάλλει στην αποφυγή της υπερπροσαρμογής (overfitting), όπου το μοντέλο αποδίδει εξαιρετικά στα δεδομένα εκπαίδευσης αλλά αποτυγχάνει σε νέα παραδείγματα, καθώς και της υποπροσαρμογής (underfitting), όπου το μοντέλο δεν καταφέρνει να αποτυπώσει επαρκώς τη δομή του προβλήματος [8], [9].

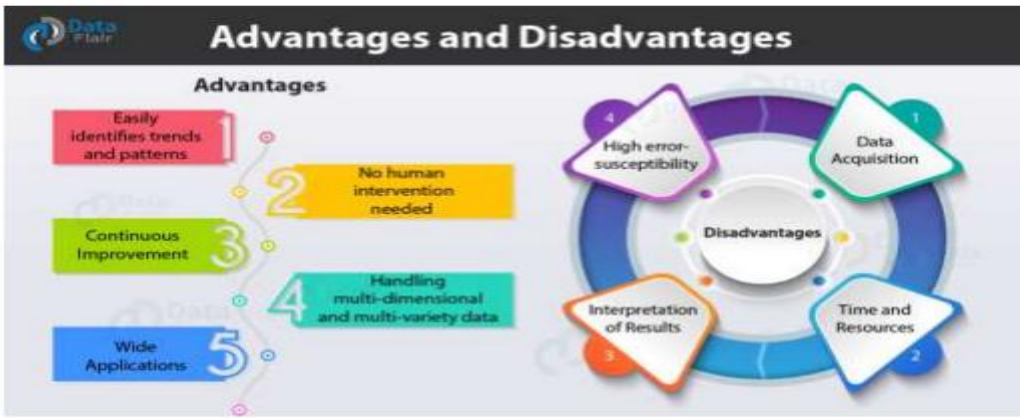
Η αξιολόγηση της απόδοσης πραγματοποιείται μέσω κατάλληλων μετρικών, όπως η ακρίβεια, η ανάκληση, ή το μέσο τετραγωνικό σφάλμα, ανάλογα με το είδος του προβλήματος. Επιπλέον, εφαρμόζεται διαδικασία βελτιστοποίησης υπερπαραμέτρων (hyperparameter tuning), προκειμένου να επιτευχθεί καλύτερη ισορροπία μεταξύ απόδοσης και γενίκευσης.

Τέλος, η ανάπτυξη ενός μοντέλου μηχανικής μάθησης δεν ολοκληρώνεται με την αρχική εκπαίδευση. Απαιτείται συνεχής παρακολούθηση της απόδοσης σε πραγματικό περιβάλλον, επανεκπαίδευση όταν μεταβάλλονται τα δεδομένα (data drift) και τακτικός έλεγχος αξιοπιστίας. Η διαχείριση αυτού του κύκλου ζωής καθιστά τα συστήματα μηχανικής μάθησης ιδιαίτερα ευέλικτα αλλά και πιο σύνθετα στη συντήρηση σε σύγκριση με τα έμπειρα συστήματα.

4.2.3 Πλεονεκτήματα και μειονεκτήματα

Τα συστήματα μηχανικής μάθησης παρουσιάζουν σημαντικά πλεονεκτήματα, καθώς είναι ικανά να μαθαίνουν αυτόματα από δεδομένα και να προσαρμόζονται σε δυναμικά περιβάλλοντα χωρίς την ανάγκη ρητού καθορισμού κανόνων. Η δυνατότητα επεξεργασίας μεγάλων όγκων δεδομένων και η εξαγωγή πολύπλοκων, μη γραμμικών σχέσεων επιτρέπουν την επίτευξη υψηλής ακρίβειας σε εφαρμογές όπως η αναγνώριση εικόνας, η ανάλυση φυσικής γλώσσας και η πρόβλεψη συμπεριφορών. Παράλληλα, τα μοντέλα μπορούν να βελτιώνουν την απόδοσή τους όσο αυξάνεται το διαθέσιμο σύνολο δεδομένων, γεγονός που καθιστά τη μηχανική μάθηση ιδιαίτερα ευέλικτη και αποτελεσματική σε πραγματικές συνθήκες. [11], [12]

Ωστόσο, η αποτελεσματικότητα των συστημάτων αυτών εξαρτάται σε μεγάλο βαθμό από την ποιότητα και την ποσότητα των δεδομένων εκπαίδευσης. Η έλλειψη επαρκών δεδομένων ή η παρουσία θορύβου μπορεί να οδηγήσει σε μειωμένη απόδοση. Επιπλέον, πολλά σύγχρονα μοντέλα, ιδιαίτερα τα μοντέλα βαθιάς μάθησης, λειτουργούν ως «μαύρα κουτιά», δυσχεραίνοντας την ερμηνεία των αποφάσεών τους. Ζητήματα όπως η μεγάλη εξειδίκευση και οι υψηλές υπολογιστικές απαιτήσεις εκπαίδευσης αποτελούν επίσης σημαντικές προκλήσεις, περιορίζοντας σε ορισμένες περιπτώσεις την αξιοπιστία και την πρακτική εφαρμογή τους. [10], [12]



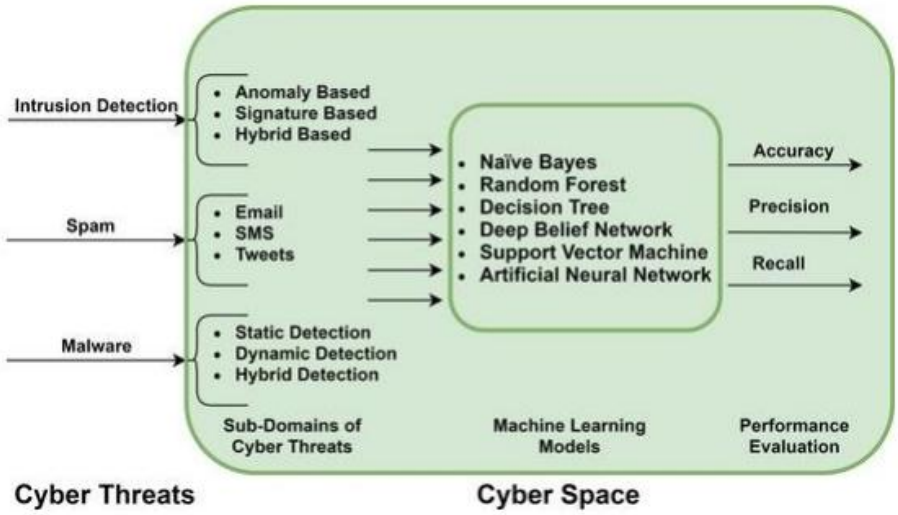
Εικόνα 4.3 Πλεονέκτημα και Μειονεκτήματα

Πηγή: [12]

4.2.4 Εφαρμογές της Μηχανικής Μάθησης

Στον τομέα της υγείας, οι τεχνικές μηχανικής μάθησης χρησιμοποιούνται εκτενώς για την υποστήριξη της ιατρικής διάγνωσης, της ανάλυσης βιοϊατρικών σημάτων και της επεξεργασίας ιατρικών εικόνων. Εκτεταμένη βιβλιογραφική ανασκόπηση δείχνει ότι οι ML μέθοδοι συμβάλλουν στην έγκαιρη ανίχνευση παθήσεων, στη βελτίωση της ακρίβειας διάγνωσης και στη νοσοκομειακή πρόγνωση, μειώνοντας σημαντικά τον χρόνο και το κόστος διάγνωσης σε κλινικά περιβάλλοντα. [13]

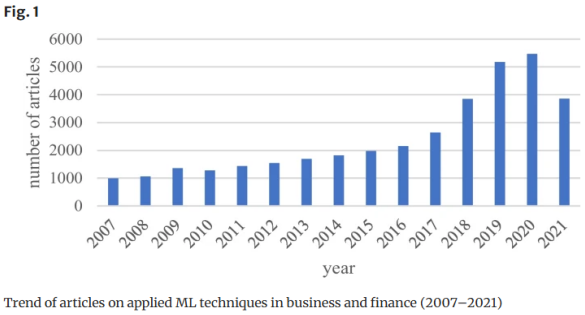
Επιπλέον, η μηχανική μάθηση έχει σημαντικό ρόλο στην ασφάλεια των πληροφοριακών συστημάτων (cybersecurity), όπου τα παραδοσιακά συστήματα ανίχνευσης απειλών βασισμένα σε κανόνες δεν επαρκούν για την αντιμετώπιση εξελισσόμενων επιθέσεων. Τεχνικές μηχανικής μάθησης χρησιμοποιούνται για την ανίχνευση εισβολών, την ταξινόμηση κακόβουλου λογισμικού και την αναγνώριση μη φυσιολογικών συμπεριφορών σε δίκτυα, επιτυγχάνοντας υψηλότερα επίπεδα ακρίβειας και ευελιξίας έναντι των συμβατικών μεθόδων. Η βιβλιογραφία υπογραμμίζει ότι οι εφαρμογές αυτές δείχνουν σημαντική βελτίωση στα ποσοστά εντοπισμού απειλών, αν και απαιτούν υψηλής ποιότητας δεδομένα και συνεχείς ενημερώσεις για την αντιμετώπιση νέων μορφών επιθέσεων.[14]



Εικόνα 4.4 Εφαρμογή μοντέλων μηχανικής μάθησης για την ανίχνευση κυβερνοαπειλών και την αξιολόγηση απόδοσης

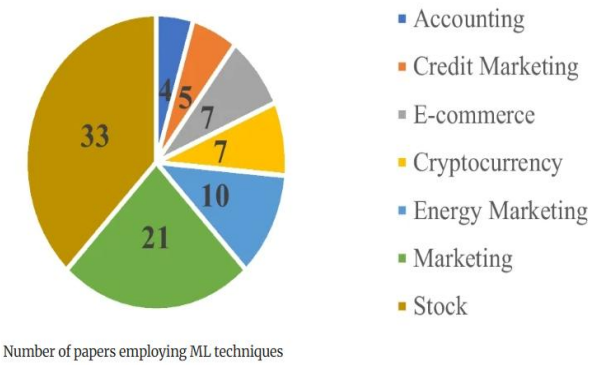
Πηγή: [14]

Επιπλέον, στη βιβλιογραφία έχουν μελετηθεί εκτενώς οι εφαρμογές της μηχανικής μάθησης στους τομείς των επιχειρήσεων και των χρηματοοικονομικών. Μια πρόσφατη επισκόπηση καταγράφει πάνω από 100 άρθρα που εφαρμόζουν τεχνικές μηχανικής μάθησης σε προβλήματα όπως ανάλυση μετοχών, πρόβλεψη ζήτησης, marketing και ανίχνευση χρηματοοικονομικών εγκλημάτων. Τα ευρήματα δείχνουν ότι μέθοδοι βαθιάς μάθησης και αναλυτικά μοντέλα συμβάλλουν στην βελτίωση των διαδικασιών λήψης αποφάσεων και στην ακριβέστερη πρόβλεψη χρηματοοικονομικών αποτελεσμάτων, αποδεικνύοντας την αξία της μηχανικής μάθησης σε σύγχρονα επιχειρησιακά περιβάλλοντα. [15]



Εικόνα 4.5 Εξέλιξη του αριθμού δημοσιεύσεων που εφαρμόζουν τεχνικές μηχανικής μάθησης

Πηγή: [15]



Διάγραμμα 4.1 Κατανομή εφαρμογών μηχανικής μάθησης στους τομείς επιχειρήσεων

Πηγή: [15]

4.3 Συγκριτική Ανάλυση και Εφαρμογές

4.3.1 Ομοιότητες

Παρά τις τεχνικές διαφορές που χαρακτηρίζουν τα Έμπειρα Συστήματα και τα Συστήματα Μηχανικής Μάθησης, οι δύο προσεγγίσεις μοιράζονται κοινή φιλοσοφία και παρόμοιους στόχους. Και οι δύο τεχνολογίες επιδιώκουν την ανάπτυξη υπολογιστικών συστημάτων ικανών να προσομοιώνουν την ανθρώπινη σκέψη και να υποστηρίζουν τη διαδικασία λήψης αποφάσεων σε σύνθετα προβλήματα. Είτε μέσω ρητά διατυπωμένων κανόνων γνώσης, όπως συμβαίνει στα έμπειρα συστήματα, είτε μέσω εκμάθησης προτύπων από δεδομένα, όπως στη μηχανική μάθηση, ο τελικός στόχος παραμένει η παροχή αξιόπιστων συμπερασμάτων και προβλέψεων [1], [6].

Επιπλέον, εφαρμόζονται σε παρόμοιους τομείς, όπως η ιατρική διάγνωση, τα χρηματοοικονομικά και τα συστήματα υποστήριξης αποφάσεων, όπου απαιτείται ανάλυση πληροφοριών και τεκμηριωμένη αξιολόγηση εναλλακτικών λύσεων [3], [15]. Μέσω της αυτοματοποίησης διαδικασιών και της συστηματικής επεξεργασίας δεδομένων, συμβάλλουν στη βελτίωση της αποδοτικότητας και της συνέπειας των αποτελεσμάτων, λειτουργώντας ως εργαλεία ενίσχυσης της ανθρώπινης κρίσης.

Συνεπώς, τόσο τα έμπειρα συστήματα όσο και τα μοντέλα μηχανικής μάθησης συμβάλλουν στην αυτοματοποίηση διαδικασιών και στη μείωση του ανθρώπινου φόρτου εργασίας. Μέσω της συστηματικής αξιοποίησης δεδομένων, επιτρέπουν την επεξεργασία μεγάλου όγκου πληροφοριών και τη συνεπή παραγωγή αποτελεσμάτων. Τα χαρακτηριστικά αυτά τα καθιστούν ιδιαίτερα χρήσιμα σε σύγχρονα πληροφοριακά περιβάλλοντα [7].

4.3.2 Διαφορές

Παρά τις ομοιότητες ως προς τον σκοπό τους, τα Έμπειρα Συστήματα και τα Συστήματα Μηχανικής Μάθησης διαφέρουν σημαντικά ως προς τον τρόπο αναπαράστασης της γνώσης και τη μεθοδολογία λειτουργίας τους. Τα έμπειρα συστήματα βασίζονται σε ρητά καθορισμένους κανόνες γνώσης που εισάγονται από ειδικούς του πεδίου, ενώ η μηχανική μάθηση στηρίζεται σε δεδομένα και αλγορίθμους εκπαίδευσης που επιτρέπουν στο σύστημα να μαθαίνει αυτόματα πρότυπα και σχέσεις [1], [7].

Επιπλέον, τα expert systems χαρακτηρίζονται από υψηλή ερμηνευσιμότητα, καθώς κάθε απόφαση μπορεί να αιτιολογηθεί μέσω συγκεκριμένων κανόνων. Αντίθετα, πολλά μοντέλα μηχανικής μάθησης, ιδιαίτερα τα μοντέλα βαθιάς μάθησης, λειτουργούν ως «μαύρα κουτιά», καθιστώντας δυσκολότερη την κατανόηση της λογικής των αποτελεσμάτων [6].

Τέλος, τα έμπειρα συστήματα απαιτούν χειροκίνητη κατασκευή και συντήρηση της βάσης γνώσης, γεγονός που περιορίζει την επεκτασιμότητά τους, ενώ τα συστήματα μηχανικής μάθησης μπορούν να προσαρμόζονται δυναμικά μέσω νέων δεδομένων, προσφέροντας μεγαλύτερη ευελιξία και καλύτερη απόδοση σε μεγάλης κλίμακας προβλήματα.

4.3.3 Πίνακας σύγκρισης

Πίνακας 4.1 Σύγκριση βασικών χαρακτηριστικών Έμπειρων Συστημάτων και Μηχανικής Μάθησης

Χαρακτηριστικό	**Έμπειρα Συστήματα**	**Μηχανική Μάθηση**
Τρόπος γνώσης	Ρητοί κανόνες (IF–THEN)	Εκμάθηση από δεδομένα
Ανάπτυξη	Χειροκίνητη εισαγωγή γνώσης από ειδικούς	Εκπαίδευση μοντέλων με αλγορίθμους
Απαιτήσεις δεδομένων	Μικρές	Μεγάλες ποσότητες δεδομένων
Ερμηνευσιμότητα	Υψηλή	Χαμηλή (black-box)
Προσαρμοστικότητα	Περιορισμένη	Υψηλή, μέσω επανεκπαίδευσης
Κλιμάκωση	Δύσκολη με πολλούς κανόνες	Κατάλληλη για μεγάλα datasets
Συντήρηση	Χρονοβόρα	Αυτόματη βελτίωση μέσω μάθησης

4.3.4 Σύγχρονες υβριδικές προσεγγίσεις

Η σύγκριση μεταξύ Έμπειρων Συστημάτων και Συστημάτων Μηχανικής Μάθησης καταδεικνύει ότι καμία από τις δύο προσεγγίσεις δεν μπορεί να θεωρηθεί επαρκής για όλα τα είδη προβλημάτων. Τα έμπειρα συστήματα διακρίνονται για τη διαφάνεια, την ερμηνευσιμότητα και τη σαφή αναπαράσταση της γνώσης, καθώς βασίζονται σε ρητούς κανόνες και λογικούς μηχανισμούς συλλογισμού. Ωστόσο, παρουσιάζουν περιορισμένη προσαρμοστικότητα και δυσκολία διαχείρισης σύνθετων ή δυναμικών δεδομένων. Αντίθετα, τα μοντέλα μηχανικής μάθησης επιτυγχάνουν υψηλή ακρίβεια και ικανότητα γενίκευσης μέσω της ανάλυσης μεγάλων συνόλων δεδομένων, αλλά συχνά λειτουργούν ως «μαύρα κουτιά», περιορίζοντας την κατανόηση και αιτιολόγηση των αποφάσεων που λαμβάνουν [1], [6].

Η διαπίστωση αυτή έχει οδηγήσει τη σύγχρονη έρευνα στην ανάπτυξη υβριδικών προσεγγίσεων, οι οποίες επιχειρούν να συνδυάσουν τα πλεονεκτήματα των δύο τεχνολογιών. Σε τέτοιες αρχιτεκτονικές, η γνώση ειδικών μπορεί να ενσωματωθεί υπό μορφή κανόνων, περιορισμών ή λογικών δομών, ενώ παράλληλα χρησιμοποιούνται αλγόριθμοι μηχανικής μάθησης για την επεξεργασία δεδομένων και τη βελτίωση της απόδοσης του συστήματος. Με αυτόν τον τρόπο επιδιώκεται η επίτευξη ισορροπίας μεταξύ ακρίβειας, προσαρμοστικότητας και ερμηνευσιμότητας, ενισχύοντας τη συνολική αξιοπιστία του συστήματος.

Υβριδικές λύσεις έχουν ήδη εφαρμοστεί σε τομείς όπως η ιατρική διάγνωση, η κυβερνοασφάλεια και τα χρηματοοικονομικά συστήματα, όπου απαιτείται ταυτόχρονα υψηλή απόδοση και τεκμηριωμένη λήψη αποφάσεων [3], [14], [15]. Η τάση αυτή υποδηλώνει ότι το μέλλον της τεχνητής νοημοσύνης δεν βρίσκεται στην αντικατάσταση της μιας προσέγγισης από την άλλη, αλλά στον δημιουργικό συνδυασμό τους, με στόχο την ανάπτυξη πιο ισορροπημένων και πρακτικά αξιοποιήσιμων συστημάτων.

4.3.5 Περιορισμοί και προκλήσεις σε δυναμικά περιβάλλοντα

Στην περίπτωση των Έμπειρων Συστημάτων, η στατική φύση της βάσης γνώσης περιορίζει την ικανότητά τους να προσαρμόζονται σε νέα ή μη προβλεπόμενα σενάρια. Η ενημέρωση των κανόνων απαιτεί ανθρώπινη παρέμβαση και επανέλεγχο της συνολικής λογικής συνοχής του συστήματος, γεγονός που καθιστά δύσκολη την άμεση ανταπόκριση σε ταχέως μεταβαλλόμενα περιβάλλοντα. Παρότι η ερμηνευσιμότητα και η προβλεψιμότητα αποτελούν σημαντικά πλεονεκτήματα, η έλλειψη μηχανισμού αυτόματης μάθησης περιορίζει την ευελιξία τους σε περιπτώσεις όπου τα δεδομένα εξελίσσονται συνεχώς [1], [2].

Αντίστοιχα, τα Συστήματα Μηχανικής Μάθησης, αν και διαθέτουν ικανότητα προσαρμογής μέσω επανεκπαίδευσης, αντιμετωπίζουν προκλήσεις όπως το φαινόμενο της μεταβολής κατανομής δεδομένων (data drift) και της υποβάθμισης απόδοσης με την πάροδο του χρόνου. Η ανάγκη για συνεχή παρακολούθηση, και επανεκπαίδευση αυξάνει την τεχνική πολυπλοκότητα και το λειτουργικό κόστος [37], [41]. Επιπλέον, η ευαισθησία ορισμένων μοντέλων σε μικρές μεταβολές των δεδομένων εισόδου μπορεί να επηρεάσει την αξιοπιστία τους σε κρίσιμες εφαρμογές.

Σε περιβάλλοντα υψηλού ρίσκου, όπως η υγειονομική περίθαλψη ή τα χρηματοοικονομικά συστήματα, οι παραπάνω περιορισμοί καθιστούν αναγκαία την ύπαρξη μηχανισμών ελέγχου, επικύρωσης και ανθρώπινης εποπτείας (human-in-the-loop). Συνεπώς, η επιλογή τεχνολογίας πρέπει να λαμβάνει υπόψη όχι μόνο την αρχική απόδοση, αλλά και τη μακροχρόνια σταθερότητα, την προσαρμοστικότητα και το επίπεδο ρίσκου του περιβάλλοντος εφαρμογής. Με τον τρόπο αυτό γίνεται σαφές ότι η επιλογή του συστήματος που θα είναι καλύτερο και πιο εξυπηρετικό αλλά κυρίως πιο έμπιστο και κατάλληλο είναι ζήτημα υψίστης σημασίας, διότι το περιθώριο λάθους σε τέτοιους τομής πρέπει να είναι όσο το δυνατόν μικρότερο.

5 Υπολογιστικές απαιτήσεις και πρακτικοί περιορισμοί

5.1 Απαιτήσεις δεδομένων και εκπαίδευσης

Οι απαιτήσεις σε δεδομένα και διαδικασίες εκπαίδευσης αποτελούν βασικό σημείο διαφοροποίησης μεταξύ Έμπειρων Συστημάτων και Συστημάτων Μηχανικής Μάθησης, καθώς αντανακλούν διαφορετικές φιλοσοφίες σχεδίασης και διαφορετικούς τρόπους απόκτησης γνώσης. Τα έμπειρα συστήματα βασίζονται στη ρητή αναπαράσταση γνώσης μέσω κανόνων που εισάγονται από ανθρώπινους ειδικούς. Η γνώση ενσωματώνεται απευθείας στη βάση γνώσης του συστήματος, γεγονός που περιορίζει σημαντικά την ανάγκη συλλογής μεγάλων συνόλων δεδομένων και εξαλείφει τη διαδικασία εκπαίδευσης με τη συμβατική έννοια της βελτιστοποίησης παραμέτρων. Η λειτουργία τους παραμένει σχετικά σταθερή μετά την ανάπτυξη, ενώ η απόδοσή τους εξαρτάται κυρίως από την ποιότητα, την πληρότητα και τη συνέπεια των κανόνων που έχουν οριστεί. Ωστόσο, η διαδικασία απόκτησης γνώσης από ειδικούς μπορεί να είναι χρονοβόρα και απαιτεί συστηματική επικύρωση.

Αντίθετα, τα συστήματα μηχανικής μάθησης στηρίζονται στην ανάλυση δεδομένων για την αυτόματη εξαγωγή προτύπων και τη βελτιστοποίηση παραμέτρων. Η αποτελεσματικότητά τους συνδέεται άμεσα με τη διαθεσιμότητα μεγάλων και ποιοτικών συνόλων δεδομένων, καθώς και με τη σωστή προεπεξεργασία, κανονικοποίηση και επισήμανσή τους. Οι επαναλαμβανόμενοι κύκλοι εκπαίδευσης, αξιολόγησης και βελτιστοποίησης αυξάνουν σημαντικά τον χρόνο και το κόστος ανάπτυξης, ενώ συχνά απαιτούν εξειδικευμένο υλικό, όπως GPU ή κατανεμημένες υποδομές [16], [18], [21]. Επιπλέον, ο κύκλος ζωής ενός μοντέλου μηχανικής μάθησης δεν ολοκληρώνεται με την αρχική εκπαίδευση· απαιτείται συνεχής παρακολούθηση απόδοσης, επανεκπαίδευση και προσαρμογή σε νέα δεδομένα, γεγονός που προσθέτει πολυπλοκότητα στη συντήρηση και αυξάνει το λειτουργικό κόστος [17].

Συνεπώς, ενώ τα έμπειρα συστήματα χαρακτηρίζονται από περιορισμένες απαιτήσεις δεδομένων και προβλέψιμη λειτουργική συμπεριφορά, τα συστήματα μηχανικής μάθησης προσφέρουν μεγαλύτερη προσαρμοστικότητα και ικανότητα γενίκευσης σε σύνθετα προβλήματα, με αντάλλαγμα αυξημένο υπολογιστικό, οργανωτικό και διαχειριστικό κόστος. Η επιλογή μεταξύ των δύο προσεγγίσεων εξαρτάται τελικά από τη διαθεσιμότητα δεδομένων, τη φύση του προβλήματος και τις απαιτήσεις αξιοπιστίας της εκάστοτε εφαρμογής.

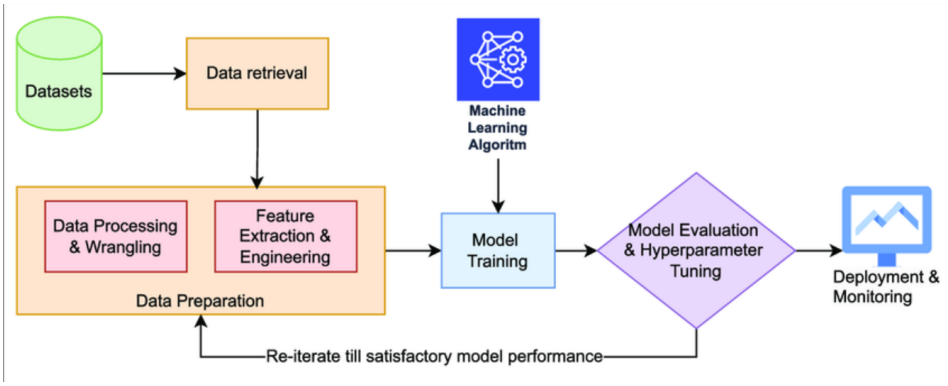
5.2 Κατανάλωση πόρων και υποδομές

5.2.1 Υπολογιστική ισχύς και χρόνος εκπαίδευσης

Η απαιτούμενη υπολογιστική ισχύς και ο χρόνος εκπαίδευσης αποτελούν βασικούς παράγοντες που επηρεάζουν την πρακτική υλοποίηση και κλιμάκωση ευφυών συστημάτων. Τα Έμπειρα Συστήματα χαρακτηρίζονται από σχετικά χαμηλές υπολογιστικές απαιτήσεις, καθώς η λειτουργία τους βασίζεται σε προκαθορισμένους κανόνες και λογικούς μηχανισμούς συμπερασμού. Η επεξεργασία περιορίζεται κυρίως στην ενεργοποίηση κανόνων και στην αξιολόγηση συνθηκών, χωρίς ανάγκη υπολογιστικά απαιτητικής βελτιστοποίησης παραμέτρων. Ως εκ τούτου, η εκτέλεσή τους μπορεί να πραγματοποιηθεί ακόμη και σε απλές υπολογιστικές πλατφόρμες, χωρίς εξειδικευμένο υλικό ή χρονοβόρα διαδικασία εκπαίδευσης, γεγονός που μειώνει το αρχικό κόστος ανάπτυξης και διευκολύνει την υλοποίηση σε περιβάλλοντα περιορισμένων πόρων [25].

Αντίθετα, τα Συστήματα Μηχανικής Μάθησης, και ιδιαίτερα οι τεχνικές βαθιάς μάθησης, απαιτούν σημαντική επεξεργαστική ισχύ κατά τη φάση εκπαίδευσης. Η ανάλυση μεγάλων συνόλων δεδομένων και η βελτιστοποίηση μεγάλου αριθμού παραμέτρων οδηγούν συχνά στη χρήση GPU, κατανεμημένων συστημάτων ή υποδομών cloud, αυξάνοντας τόσο τον χρόνο εκπαίδευσης όσο και το οικονομικό κόστος [18], [21]. Σε εφαρμογές μεγάλης κλίμακας, η εκπαίδευση μπορεί να διαρκεί από ώρες έως και ημέρες, γεγονός που επηρεάζει την ευελιξία επανεκπαίδευσης και την ταχύτητα προσαρμογής σε νέα δεδομένα.

Επιπλέον, η αυξημένη υπολογιστική πολυπλοκότητα των ML συστημάτων καθιστά αναγκαία τη βελτιστοποίηση πόρων, τη χρήση τεχνικών παραλληλοποίησης και την αποδοτική κατανομή φορτίου. Η διαχείριση αυτών των παραμέτρων είναι κρίσιμη για τη διασφάλιση αποδεκτού χρόνου απόκρισης και βιώσιμης λειτουργίας σε παραγωγικά περιβάλλοντα [16], [24]. Συνεπώς, ενώ τα ML συστήματα προσφέρουν υψηλή απόδοση και ευελιξία, συνεπάγονται σημαντικά μεγαλύτερες απαιτήσεις υποδομής σε σύγκριση με τα έμπειρα συστήματα.



Εικόνα 5.1 Σχηματική αναπαράσταση υποδομής μηχανικής μάθησης σε περιβάλλον cloud, με χρήση κατανεμημένων πόρων για εκπαίδευση και εκτέλεση μοντέλων.

5.2.2 Κατανάλωση ενέργειας και λειτουργικό κόστος

Η αυξημένη χρήση μοντέλων μηχανικής μάθησης μεγάλης κλίμακας έχει αναδείξει την κατανάλωση ενέργειας και το λειτουργικό κόστος ως κρίσιμους παράγοντες αξιολόγησης της βιωσιμότητας των συστημάτων τεχνητής νοημοσύνης. Η έννοια του “Green AI” υπογραμμίζει την ανάγκη συνεκτίμησης της ενεργειακής αποδοτικότητας και του περιβαλλοντικού αποτυπώματος κατά την ανάπτυξη και εκπαίδευση μοντέλων, ιδιαίτερα σε περιπτώσεις βαθιάς μάθησης [26], [31]. Μελέτες δείχνουν ότι η εκπαίδευση μεγάλων νευρωνικών δικτύων μπορεί να συνεπάγεται σημαντικές εκπομπές διοξειδίου του άνθρακα, ιδίως όταν πραγματοποιείται σε ενεργοβόρες υποδομές cloud [27], [32].

Παράλληλα, η αρχιτεκτονική των cloud συστημάτων και η επιλογή υλικού (GPU, TPU, accelerators) επηρεάζουν άμεσα το οικονομικό και ενεργειακό κόστος της εκπαίδευσης και εξυπηρέτησης μοντέλων [33], [35]. Η βιβλιογραφία επισημαίνει ότι η κλιμάκωση των μοντέλων χωρίς στρατηγική βελτιστοποίησης οδηγεί σε αυξημένη ενεργειακή ένταση και μη βιώσιμες πρακτικές ανάπτυξης [29], [30], ενώ η συνεχής αύξηση του μεγέθους των μοντέλων δημιουργεί επιπλέον τεχνικές και κοινωνικές προκλήσεις [34].

Συγκριτικά, τα έμπειρα συστήματα παρουσιάζουν ελάχιστες ενεργειακές απαιτήσεις κατά τη λειτουργία τους, καθώς δεν απαιτούν φάση εκπαίδευσης μεγάλης κλίμακας ούτε εξειδικευμένες υποδομές. Συνεπώς, αν και τα συστήματα μηχανικής μάθησης επιτυγχάνουν υψηλή απόδοση και ακρίβεια, το ενεργειακό και οικονομικό τους αποτύπωμα αποτελεί σημαντικό περιορισμό που πρέπει να λαμβάνεται υπόψη στη σχεδίαση και υλοποίηση σύγχρονων εφαρμογών τεχνητής νοημοσύνης [35].

Τα συγκριτικά χαρακτηριστικά ενεργειακής κατανάλωσης και λειτουργικού κόστους συνοψίζονται στον παρακάτω πίνακα.

Πίνακας 5.1 Σύγκριση ενεργειακού και λειτουργικού κόστους μεταξύ Έμπειρων Συστημάτων και Συστημάτων Μηχανικής Μάθησης.

Παράμετρος	**Έμπειρα Συστήματα**	**Μηχανική Μάθηση**
Ενεργειακή κατανάλωση κατά ανάπτυξη	Πολύ χαμηλή	Υψηλή (ιδίως σε deep learning)
Ενεργειακή κατανάλωση κατά λειτουργία	Πολύ χαμηλή	Μεσαία–Υψηλή
Ανάγκη εξειδικευμένου hardware	Όχι	Συχνά GPU / TPU
Υποδομή	Τοπικός server επαρκεί	Cloud / Distributed clusters
Λειτουργικό κόστος	Σχετικά σταθερό	Αυξανόμενο με το μέγεθος μοντέλου
Κλιμάκωση	Περιορισμένη	Υψηλή αλλά ενεργοβόρα
Περιβαλλοντικό αποτύπωμα	Μικρό	Σημαντικό σε μεγάλα μοντέλα

5.2.3 Συντήρηση, τεχνικό χρέος και αξιοπιστία

Η συντήρηση και η διαχείριση της πολυπλοκότητας αποτελούν κρίσιμους παράγοντες για τη μακροχρόνια βιωσιμότητα των συστημάτων τεχνητής νοημοσύνης. Στα Έμπειρα Συστήματα, η βασική πρόκληση εντοπίζεται στη διαχείριση και ενημέρωση της βάσης γνώσης, καθώς η προσθήκη, τροποποίηση ή αφαίρεση κανόνων μπορεί να επηρεάσει τη συνολική λογική συνοχή και συνέπεια του συστήματος. Η ανάγκη διατήρησης της εσωτερικής συνέπειας μεταξύ των κανόνων απαιτεί προσεκτικό έλεγχο και επαλήθευση. Παρ' όλα αυτά, η συμπεριφορά των συστημάτων αυτών παραμένει προβλέψιμη και διαφανής, γεγονός που διευκολύνει τον εντοπισμό σφαλμάτων και την κατανόηση της λειτουργίας τους [39].

Αντίθετα, τα συστήματα μηχανικής μάθησης χαρακτηρίζονται από αυξημένη πολυπλοκότητα κατά τον κύκλο ζωής τους, ο οποίος περιλαμβάνει στάδια συλλογής δεδομένων, εκπαίδευσης, αξιολόγησης, ανάπτυξης και συνεχούς παρακολούθησης. Η βιβλιογραφία επισημαίνει ότι τα ML συστήματα συσσωρεύουν «τεχνικό χρέος» λόγω εξαρτήσεων από δεδομένα, pipelines επεξεργασίας, παραμέτρους μοντέλων και εξωτερικά πληροφοριακά συστήματα, καθιστώντας τη συντήρηση και τον έλεγχο ιδιαίτερα απαιτητικές διαδικασίες [36], [39]. Επιπλέον, η διασφάλιση ποιότητας δεν περιορίζεται στην αρχική ανάπτυξη, αλλά απαιτεί συνεχή testing, validation και παρακολούθηση της απόδοσης των μοντέλων σε παραγωγικά περιβάλλοντα, ώστε να εντοπίζονται φαινόμενα υποβάθμισης απόδοσης ή μεταβολής των δεδομένων (data drift) [37], [42].

Ζητήματα αξιοπιστίας και ανθεκτικότητας (robustness) έχουν επίσης αναδειχθεί ως σημαντικές προκλήσεις, καθώς μικρές μεταβολές στα δεδομένα εισόδου ή μη αναμενόμενες συνθήκες λειτουργίας μπορεί να επηρεάσουν σημαντικά τα αποτελέσματα ενός μοντέλου [41]. Η ανάγκη για συστηματικές πρακτικές testing, αξιολόγησης και υιοθέτησης βέλτιστων πρακτικών μηχανικής λογισμικού στα συστήματα μηχανικής μάθησης υπογραμμίζεται από σύγχρονες έρευνες στον τομέα της μηχανικής λογισμικού και των συστημάτων τεχνητής νοημοσύνης [38], [40]. Συνεπώς, ενώ τα συστήματα αυτά προσφέρουν υψηλή προσαρμοστικότητα και απόδοση σε σύνθετα προβλήματα, συνοδεύονται από αυξημένες απαιτήσεις συντήρησης, ελέγχου και διαχείρισης κινδύνου σε σύγκριση με τα παραδοσιακά Έμπειρα Συστήματα.

5.3 Σύγχρονες τάσεις και μελλοντικές κατευθύνσεις

5.3.1 Υβριδικά συστήματα και συνδυαστικές προσεγγίσεις

Τα τελευταία χρόνια παρατηρείται αυξανόμενο ενδιαφέρον για την ανάπτυξη υβριδικών συστημάτων, τα οποία συνδυάζουν στοιχεία Έμπειρων Συστημάτων και Μηχανικής Μάθησης. Οι προσεγγίσεις αυτές επιδιώκουν να αξιοποιήσουν τα πλεονεκτήματα της συμβολικής αναπαράστασης γνώσης —όπως η διαφάνεια και η λογική ερμηνεία— μαζί με τη μαθησιακή ικανότητα και την προσαρμοστικότητα των νευρωνικών μοντέλων [43], [44]. Το πεδίο της νευρο-συμβολικής υπολογιστικής (neural-symbolic computing) προτείνει μεθοδολογίες ενσωμάτωσης κανόνων και λογικής συλλογιστικής σε συστήματα που εκπαιδεύονται από δεδομένα, επιδιώκοντας μια πιο ισορροπημένη προσέγγιση μεταξύ ερμηνευσιμότητας και απόδοσης.

Παράλληλα, η ανάγκη για διαφάνεια στα σύγχρονα συστήματα τεχνητής νοημοσύνης έχει ενισχύσει την ανάπτυξη τεχνικών Explainable AI (XAI), οι οποίες στοχεύουν στη μετατροπή των «μαύρων κουτιών» σε περισσότερο κατανοητά και ελέγξιμα συστήματα [45], [46]. Πρωτοβουλίες όπως το πρόγραμμα Explainable AI της DARPA υπογραμμίζουν τη σημασία της ερμηνευσιμότητας για την ενίσχυση της εμπιστοσύνης και της αξιοπιστίας των συστημάτων τεχνητής νοημοσύνης σε κρίσιμες εφαρμογές [47].

Συνεπώς, τα υβριδικά συστήματα αποτελούν μία σύγχρονη κατεύθυνση που επιχειρεί να γεφυρώσει το χάσμα μεταξύ των παραδοσιακών Έμπειρων Συστημάτων και των σύγχρονων μοντέλων μηχανικής μάθησης, προτείνοντας λύσεις που συνδυάζουν λογική τεκμηρίωση και μαθησιακή προσαρμοστικότητα.

5.3.2 Ερμηνευσιμότητα και αξιοπιστία στα σύγχρονα συστήματα

Η ερμηνευσιμότητα και η αξιοπιστία αποτελούν πλέον κεντρικά ζητήματα στον σχεδιασμό σύγχρονων συστημάτων τεχνητής νοημοσύνης. Η αυξανόμενη χρήση μοντέλων μηχανικής μάθησης σε κρίσιμους τομείς, όπως η υγεία, η οικονομία και η δημόσια διοίκηση, έχει αναδείξει την ανάγκη για συστήματα που δεν είναι μόνο αποδοτικά, αλλά και κατανοητά και ελέγξιμα [50], [51]. Η βιβλιογραφία επισημαίνει ότι η απλή παροχή εξηγήσεων δεν επαρκεί, εάν αυτές δεν είναι ποιοτικά αξιόπιστες και κατανοητές από τον τελικό χρήστη [53].

Παράλληλα, η ανάπτυξη κανονιστικών πλαισίων, όπως ο Ευρωπαϊκός Κανονισμός για την Τεχνητή Νοημοσύνη (AI Act), υπογραμμίζει τη σημασία της διαφάνειας, της λογοδοσίας και της διαχείρισης κινδύνου σε συστήματα υψηλής επίπτωσης [48]. Θεωρητικές προσεγγίσεις για την ηθική και κοινωνική διάσταση της τεχνητής νοημοσύνης προτείνουν σύνολα αρχών που περιλαμβάνουν τη δικαιοσύνη, τη διαφάνεια και την υπευθυνότητα ως βασικά στοιχεία σχεδίασης [49], [52].

Στο πλαίσιο αυτό, τα Έμπειρα Συστήματα παρουσιάζουν εγγενή πλεονεκτήματα ως προς την ερμηνευσιμότητα, λόγω της ρητής αναπαράστασης κανόνων. Αντίθετα, τα μοντέλα μηχανικής μάθησης απαιτούν επιπλέον μηχανισμούς εξήγησης και αξιολόγησης, προκειμένου να επιτευχθεί αντίστοιχο επίπεδο εμπιστοσύνης. Συνεπώς, η μελλοντική εξέλιξη του πεδίου φαίνεται να κατευθύνεται προς συστήματα που συνδυάζουν υψηλή απόδοση με θεσμικά και τεχνικά εγγυημένη αξιοπιστία.

5.3.3 Κριτήρια επιλογής μεταξύ Έμπειρων Συστημάτων και Μηχανικής Μάθησης

Η επιλογή μεταξύ Έμπειρων Συστημάτων και Συστημάτων Μηχανικής Μάθησης δεν αποτελεί απόλυτη τεχνική απόφαση, αλλά διαδικασία αξιολόγησης πολλαπλών παραγόντων. Καθοριστικό ρόλο διαδραματίζει το είδος του προβλήματος, η διαθεσιμότητα και ποιότητα των δεδομένων, το επίπεδο κανονιστικών απαιτήσεων και ο βαθμός αποδεκτού ρίσκου.

Σε περιπτώσεις όπου η γνώση μπορεί να αποτυπωθεί ρητά και απαιτείται υψηλή ερμηνευσιμότητα ή κανονιστική συμμόρφωση, τα Έμπειρα Συστήματα αποτελούν κατάλληλη επιλογή, ιδιαίτερα σε περιβάλλοντα με αυξημένη ανάγκη διαφάνειας και ελέγχου [46], [55]. Η προβλέψιμη συμπεριφορά τους και οι χαμηλές υπολογιστικές απαιτήσεις ενισχύουν τη χρηστικότητά τους σε ελεγχόμενα ή περιορισμένων πόρων περιβάλλοντα.

Αντίθετα, όταν υπάρχουν μεγάλα σύνολα δεδομένων και απαιτείται ικανότητα γενίκευσης ή ανίχνευσης σύνθετων προτύπων, τα συστήματα μηχανικής μάθησης υπερτερούν ως προς την απόδοση και την προσαρμοστικότητα [7], [54]. Ωστόσο, η αυξημένη πολυπλοκότητα, το ενεργειακό κόστος και οι απαιτήσεις συντήρησης που έχουν επισημανθεί στη σύγχρονη βιβλιογραφία [26], [37] αποτελούν παράγοντες που πρέπει να συνεκτιμώνται πριν την υιοθέτηση.

Συνεπώς, η επιλογή τεχνολογίας είναι πολυπαραγοντική και εξαρτάται από τη φύση του προβλήματος, το διαθέσιμο οικοσύστημα δεδομένων, το κόστος υποδομής και τις απαιτήσεις ερμηνευσιμότητας. Σε πολλές σύγχρονες εφαρμογές, υβριδικές προσεγγίσεις προσφέρουν μια ισορροπημένη λύση, συνδυάζοντας λογική τεκμηρίωση και μαθησιακή προσαρμοστικότητα σε ενιαίο πλαίσιο [43], [44].

5.4 Ρυθμιστικά και Ηθικά Ζητήματα στην Τεχνητή Νοημοσύνη

5.4.1 Ζητήματα Ηθικής και Υπευθυνότητας

Η αυξανόμενη αξιοποίηση συστημάτων τεχνητής νοημοσύνης σε κρίσιμους τομείς, όπως η υγεία, τα χρηματοοικονομικά και η κυβερνοασφάλεια, έχει αναδείξει σημαντικά ζητήματα ηθικής και υπευθυνότητας. Η βιβλιογραφία επισημαίνει ότι η απόδοση ενός συστήματος δεν αρκεί από μόνη της, εάν δεν συνοδεύεται από διαφάνεια, δυνατότητα ελέγχου και σαφή κατανομή ευθύνης [50], [51]. Ιδιαίτερα στα Συστήματα Μηχανικής Μάθησης, η ύπαρξη μεροληψίας στα δεδομένα εκπαίδευσης μπορεί να οδηγήσει σε άνιση ή άδικη λήψη αποφάσεων, γεγονός που καθιστά απαραίτητη τη συστηματική αξιολόγηση της δικαιοσύνης και της ποιότητας των δεδομένων [9], [53].

Επιπλέον, η πολυπλοκότητα των μοντέλων βαθιάς μάθησης περιορίζει συχνά τη δυνατότητα πλήρους κατανόησης του τρόπου με τον οποίο παράγονται οι αποφάσεις. Για τον λόγο αυτό, η έρευνα στον τομέα της Explainable AI (XAI) επιδιώκει την ανάπτυξη τεχνικών που καθιστούν τα μοντέλα περισσότερο κατανοητά και ελέγξιμα [45], [46]. Παράλληλα, η διασφάλιση της αξιοπιστίας καθ’ όλο τον κύκλο ζωής ενός ML συστήματος απαιτεί διαδικασίες ελέγχου, τεκμηρίωσης και παρακολούθησης της απόδοσης, όπως επισημαίνεται στη σύγχρονη βιβλιογραφία περί assurance και ML lifecycle [8], [36].

Σε αντίθεση με τα συστήματα μηχανικής μάθησης, τα Έμπειρα Συστήματα διαθέτουν διαφάνεια, καθώς βασίζονται σε ρητούς κανόνες που μπορούν να εξεταστούν και να επαληθευθούν. Ωστόσο, η ευθύνη μετατοπίζεται στη διαδικασία απόκτησης γνώσης και στη σωστή διαμόρφωση των κανόνων, δεδομένου ότι σφάλματα ή προκαταλήψεις στη βάση γνώσης μπορούν να επηρεάσουν άμεσα τα αποτελέσματα. Συνεπώς, η ηθική διάσταση αφορά τόσο τα δεδομένα όσο και τη διαδικασία σχεδίασης του συστήματος.

Η ανάγκη θεσμικής ρύθμισης της τεχνητής νοημοσύνης αποτυπώνεται και στην ανάπτυξη κανονιστικών πλαισίων, όπως ο Ευρωπαϊκός Κανονισμός για την Τεχνητή Νοημοσύνη (AI Act), ο οποίος θέτει απαιτήσεις διαφάνειας, διαχείρισης κινδύνου και λογοδοσίας για συστήματα υψηλού ρίσκου [48], [49]. Οι αρχές της υπευθυνότητας, της δικαιοσύνης και της διαφάνειας αποτελούν πλέον βασικά κριτήρια αξιολόγησης κάθε ευφυούς συστήματος, ανεξαρτήτως της τεχνολογικής προσέγγισης.

5.4.2 Επιπτώσεις στην επιλογή τεχνολογίας

Τα ηθικά και κανονιστικά ζητήματα επηρεάζουν ουσιαστικά την επιλογή μεταξύ Έμπειρων Συστημάτων και Συστημάτων Μηχανικής Μάθησης. Σε περιβάλλοντα υψηλής κανονιστικής συμμόρφωσης, όπου απαιτείται σαφής τεκμηρίωση και δυνατότητα αναδρομής στη διαδικασία λήψης αποφάσεων, τα Έμπειρα Συστήματα εμφανίζουν πλεονεκτήματα λόγω της δομημένης και ερμηνεύσιμης φύσης τους [43]. Η δυνατότητα ελέγχου των κανόνων διευκολύνει τη λογοδοσία και τη συμμόρφωση με θεσμικά πλαίσια.

Αντίθετα, σε περιβάλλοντα όπου η πολυπλοκότητα των δεδομένων είναι υψηλή και απαιτείται ικανότητα γενίκευσης, τα Συστήματα Μηχανικής Μάθησης υπερέχουν ως προς την απόδοση και την προσαρμοστικότητα [7], [15]. Ωστόσο, η βιβλιογραφία επισημαίνει ότι η αυξημένη τεχνική πολυπλοκότητα, το «τεχνικό χρέος» και οι εξαρτήσεις από δεδομένα και υποδομές καθιστούν τη συντήρηση και τον έλεγχο πιο απαιτητικά [36], [39]. Επιπλέον, ζητήματα αξιοπιστίας και ανθεκτικότητας (robustness) πρέπει να αξιολογούνται συστηματικά, ιδιαίτερα σε κρίσιμες εφαρμογές [41], [14].

Η επιλογή τεχνολογίας, επομένως, δεν αποτελεί αποκλειστικά τεχνική απόφαση. Περιλαμβάνει αξιολόγηση ρίσκου, διαθέσιμων δεδομένων, υπολογιστικών πόρων, κανονιστικών απαιτήσεων και κοινωνικών επιπτώσεων. Σε πολλές σύγχρονες εφαρμογές, υβριδικές προσεγγίσεις προτείνονται ως ισορροπημένη λύση, συνδυάζοντας τη λογική τεκμηρίωση των έμπειρων συστημάτων με τη μαθησιακή ικανότητα των μοντέλων μηχανικής μάθησης [43], [44]. Με τον τρόπο αυτό επιδιώκεται η επίτευξη υψηλής απόδοσης χωρίς να παραμελείται η διαφάνεια και η αξιοπιστία.

Αποτελέσματα και Ανάλυση

Η παρούσα εργασία επιδίωξε τη συγκριτική μελέτη των Έμπειρων Συστημάτων και των Συστημάτων Μηχανικής Μάθησης, εξετάζοντας τις θεωρητικές τους βάσεις, την αρχιτεκτονική τους δομή, τις πρακτικές εφαρμογές τους και τις σύγχρονες εξελίξεις στον χώρο της τεχνητής νοημοσύνης. Από την ανάλυση που προηγήθηκε προκύπτει ότι, παρά την κοινή τους ένταξη στο ευρύτερο πεδίο της Τεχνητής Νοημοσύνης, οι δύο αυτές προσεγγίσεις βασίζονται σε διαφορετικές φιλοσοφίες σχεδίασης και παρουσιάζουν διακριτά πλεονεκτήματα και περιορισμούς.

Τα Έμπειρα Συστήματα θεμελιώνονται στη ρητή αναπαράσταση γνώσης και στη συμβολική λογική συλλογιστική. Η δυνατότητα αιτιολόγησης των αποφάσεων μέσω κανόνων «ΑΝ–ΤΟΤΕ» τα καθιστά διαφανή και ερμηνεύσιμα, χαρακτηριστικά ιδιαίτερα σημαντικά σε εφαρμογές υψηλής ευθύνης. Παράλληλα, οι χαμηλές υπολογιστικές απαιτήσεις και η σταθερή συμπεριφορά τους τα καθιστούν κατάλληλα για περιβάλλοντα με περιορισμένους πόρους ή αυστηρές κανονιστικές απαιτήσεις. Ωστόσο, η δυσκολία απόκτησης και ενημέρωσης γνώσης, καθώς και η περιορισμένη ικανότητα προσαρμογής σε νέα δεδομένα, αποτελούν σημαντικούς περιορισμούς της προσέγγισης αυτής.

Αντίθετα, τα Συστήματα Μηχανικής Μάθησης βασίζονται στην ανάλυση μεγάλων όγκων δεδομένων και στην αυτόματη εξαγωγή προτύπων. Η ικανότητα γενίκευσης και η υψηλή απόδοση σε σύνθετα προβλήματα τα καθιστούν ιδιαίτερα αποτελεσματικά σε τομείς όπως η αναγνώριση εικόνας, η επεξεργασία φυσικής γλώσσας και η κυβερνοασφάλεια. Παρόλα αυτά, η εξάρτησή τους από ποιοτικά και εκτεταμένα σύνολα δεδομένων, οι αυξημένες απαιτήσεις σε υπολογιστική ισχύ και ενέργεια, καθώς και τα ζητήματα ερμηνευσιμότητας και αξιοπιστίας, αναδεικνύουν τη σημασία προσεκτικού σχεδιασμού και συνεχούς παρακολούθησης του κύκλου ζωής τους.

Η σύγκριση των δύο προσεγγίσεων κατέδειξε ότι δεν υφίσταται απόλυτη υπεροχή της μίας έναντι της άλλης. Αντιθέτως, η επιλογή τεχνολογίας είναι πολυπαραγοντική και εξαρτάται από τη φύση του προβλήματος, τη διαθεσιμότητα δεδομένων, το επίπεδο ρίσκου, το κόστος υποδομής και την ανάγκη ερμηνευσιμότητας. Σε εφαρμογές όπου η λογική τεκμηρίωση και η διαφάνεια είναι κρίσιμες, τα έμπειρα συστήματα παραμένουν επίκαιρα. Σε δυναμικά περιβάλλοντα με μεγάλους όγκους δεδομένων, η μηχανική μάθηση προσφέρει σαφή πλεονεκτήματα.

Ιδιαίτερο ενδιαφέρον παρουσιάζει η σύγχρονη τάση σύγκλισης των δύο προσεγγίσεων μέσω υβριδικών και νευρο-συμβολικών συστημάτων. Οι συνδυαστικές αυτές λύσεις επιδιώκουν να ενσωματώσουν τη λογική ερμηνευσιμότητα των κανονοκεντρικών μοντέλων με τη μαθησιακή ικανότητα των νευρωνικών δικτύων, προσφέροντας ένα πιο ισορροπημένο πλαίσιο ανάπτυξης ευφυών συστημάτων. Παράλληλα, η αυξανόμενη έμφαση στη διαφάνεια, στη λογοδοσία και στη ρυθμιστική συμμόρφωση υποδεικνύει ότι το μέλλον της τεχνητής νοημοσύνης δεν θα βασίζεται αποκλειστικά στην απόδοση, αλλά και στην αξιοπιστία και κοινωνική αποδοχή των συστημάτων.

Συνολικά, η μελέτη ανέδειξε ότι τα Έμπειρα Συστήματα και τα Συστήματα Μηχανικής Μάθησης δεν πρέπει να θεωρούνται ανταγωνιστικές αλλά συμπληρωματικές τεχνολογίες. Η βέλτιστη προσέγγιση προκύπτει συχνά από τον συνδυασμό των πλεονεκτημάτων τους, με γνώμονα τις απαιτήσεις της εκάστοτε εφαρμογής. Η περαιτέρω έρευνα στον τομέα των υβριδικών συστημάτων, της ενεργειακής αποδοτικότητας και της ερμηνευσιμότητας αναμένεται να διαμορφώσει το επόμενο στάδιο εξέλιξης της τεχνητής νοημοσύνης, ενισχύοντας τη βιωσιμότητα και την κοινωνική της ενσωμάτωση.

Βιβλιογραφία

[1] Tan, C. F., Wahidin, L. S., Khalil, S. N., Tamaldin, N., Hu, J., & Rauterberg, G. W. M. (2016). The application of expert system: A review of research and applications. ARPN Journal of Engineering and Applied Sciences, 2448–2453.

[2] Janjanam, D., Ganesh, B., & Manjunatha, L. (2021). Design of an expert system architecture: An overview. Journal of Physics: Conference Series, 1767, 012036.

[3] Adewole, K. S., Mojeed, H. A., Ogunmodede, J. A., Gabralla, L. A., Faruk, N., Abdulkarim, A., Ifada, E., Folawiyo, Y. Y., Oloyede, A. A., Olawoyin, L. A., et al. (2022). Expert System and Decision Support System for Electrocardiogram Interpretation and Diagnosis: Review, Challenges and Research Directions. Applied Sciences, 12(23), 12342.

[4] Supriyadi, S., & Wiliyanto, D. A. (2022). Prototype expert system application to identify specific children learning disabilities in inclusion schools. Indonesian Journal of Disability Studies, 8(1), 117–127.

[5] Er, B., & Güneysu, Y. (2023). A web-based expert system application for working capital management. Ege Academic Review, 23(3), 393–408.

[6] Janiesch, C., Zschech, P., & Heinrich, K. (2021). Machine learning and deep learning. Electronic Markets, 31, 685–695.

[7] Sarker, I. H. (2021). Machine Learning: Algorithms, real-world applications and research directions. SN Computer Science, 2(3), 160.

[8] Ashmore, R., Calinescu, R., & Paterson, C. (2021). Assuring the machine learning lifecycle: Desiderata, methods, and challenges. IEEE Computer, 54(5), 39–47.

[9] Khan, M. A., et al. (2022). Data preprocessing for supervised machine learning: A survey. SN Computer Science, 3, 1–21.

[10] Zhang, C., Bengio, S., Hardt, M., Recht, B., & Vinyals, O. (2021). Understanding deep learning (still) requires rethinking generalization. Communications of the ACM, 64(3), 107–115.

[11] Dahiya, N., Gupta, S., & Singh, S. (2022). A review paper on machine learning applications, advantages, and techniques. ECS Transactions, 107(1), 6137.

[12] Khanzode, K. C. A., & Sarode, R. D. (2020). Advantages and disadvantages of artificial intelligence and machine learning: A literature review. International Journal of Library & Information Science (IJLIS), 9(1), 30–36.

[13] Smith, J., & Lee, A. (2022). Artificial intelligence applications in healthcare: advances and challenges. Journal of Healthcare Informatics, 35, 123–145.

[14] Vourganas, I. J., & Michala, A. L. (2024). Applications of machine learning in cyber security: A review. Journal of Cybersecurity and Privacy, 4, 972–992.

[15] Gao, H., Kou, G., Liang, H., Zhang, H., Chao, X., Li, C.-C., & Dong, Y. (2024). Machine learning in business and finance: a literature review and research opportunities. Financial Innovation, 10(1), 86.

[16] Chen, C., Liu, Z., & Wang, Y. (2020). Deep learning on computational-resource-limited platforms: A survey. IEEE Access, 8, 123045–123062.

[17] Ashmore, R., Calinescu, R., & Paterson, C. (2021). Assuring the machine learning lifecycle: Desiderata, methods, and challenges. IEEE Computer, 54(5), 39–47.

[18] Truong, H. L., Dustdar, S., & Zhang, S. (2023). Efficient distributed machine learning under resource constraints. Journal of Systems Architecture, 137, 102820.

[19] Haddadha, P. K., Rezvani, M. H., & MollaMotalebi, M. (2024). Machine learning methods for service placement: A systematic review. Artificial Intelligence Review, 57, 102.

[20] Shi, Y. (2025). Machine learning approaches for uncertainty quantification: A survey. Engineering Applications of Artificial Intelligence, 130, 107563.

[21] Wei, H., Li, Q., & Zhang, J. (2025). Optimizing machine learning operations in multi-cloud environments: Cost, performance and sustainability. Journal of Cloud Computing, 14(2), 45.

[22] Nicholson, M., & Ellis, J. (2024). Computational cost versus detection performance in IoT intrusion detection systems using machine learning. Journal of Cyber Security Technology, 8(3), 215–230.

[23] Akinrogunde, O. O., Adelakun, A. A., & Thomas, T. G. (2025). Machine learning and deep learning approaches for energy forecasting: A systematic review. Journal of Intelligent & Fuzzy Systems, 48(1), 1221–1239.

[24] Paleyes, A., Urma, R., & Lawrence, N. D. (2022). Challenges in deploying machine learning: A survey of case studies. ACM Computing Surveys, 55(5), 1–36.

[25] Sculley, D., Holt, G., Golovin, D., et al. (2021). Hidden technical debt in machine learning systems. Communications of the ACM, 64(3), 114–123.

[26] Schwartz, R., Dodge, J., Smith, N. A., & Etzioni, O. (2020). Green AI. Communications of the ACM.

[27] Patterson, D., Gonzalez, J., Le, Q., et al. (2021). Carbon emissions and large neural network training. arXiv.

[28] Henderson, P., Hu, J., Romoff, J., et al. (2020). Towards the systematic reporting of the energy and carbon footprints of machine learning. Journal of Machine Learning Research.

[29] Wu, C., Raghavendra, R., & Annavaram, M. (2022). A survey on energy-efficient deep learning. IEEE Access.

[30] Li, T., Zhao, Y., & Wang, X. (2023). Energy-efficient deep learning: A comprehensive survey. ACM Computing Surveys.

[31] Strubell, E., Ganesh, A., & McCallum, A. (2020). Energy and policy considerations for deep learning in NLP. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, 3645–3650.

[32] Anthony, L. F. W., Kanding, B., & Selvan, R. (2020). Carbontracker: Tracking and predicting the carbon footprint of training deep learning models. Proceedings of the ICML Workshop on Tackling Climate Change with Machine Learning.

[33] Gupta, U., Kim, Y. G., Lee, S., et al. (2022). The architectural implications of cloud machine learning. IEEE Micro, 42(3), 32–41.

[34] Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). On the dangers of stochastic parrots: Can language models be too big? Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency (FAccT), 610–623.

[35] Dodge, J., Prewitt, T., Tachet des Combes, R., et al. (2022). Measuring the carbon intensity of AI in cloud environments. Proceedings of the ACM SIGEnergy Conference, 1–12.

[36] Breck, E., Cai, S., Nielsen, E., Salib, M., & Sculley, D. (2021). The ML test score: A rubric for ML production readiness and technical debt reduction. Proceedings of the IEEE International Conference on Big Data, 1123–1132.

[37] Ashmore, R., Calinescu, R., & Paterson, C. (2021). Assuring the machine learning lifecycle: Desiderata, methods, and challenges. IEEE Computer, 54(5), 39–47.

[38] Zhang, Y., Harman, M., & Ma, L. (2020). Machine learning testing: Survey, landscapes and horizons. IEEE Transactions on Software Engineering, 48(1), 1–36.

[39] Amershi, S., Begel, A., Bird, C., DeLine, R., Gall, H., Kamar, E., Nagappan, N., Nushi, B., & Zimmermann, T. (2019). Software engineering for machine learning: A case study. Proceedings of the 41st International Conference on Software Engineering (ICSE), 291–300.

[40] Serban, F., van der Blom, K., Hoos, H. H., & Visser, J. (2021). Adoption and effects of software engineering best practices in machine learning. Empirical Software Engineering, 26, 1–49.

[41] Nguyen, A., Yosinski, J., & Clune, J. (2021). Deep neural networks are easily fooled: High confidence predictions for unrecognizable images. ACM Computing Surveys, 54(4), 1–36.

[42] Paleyes, A., Urma, R.-G., & Lawrence, N. D. (2022). Challenges in deploying machine learning: A survey of case studies. ACM Computing Surveys, 55(6), 1–29.

[43] Garcez, A. d'Avila, Lamb, L. C., & Gabbay, D. (2020). Neural-symbolic computing: An effective methodology for principled integration of machine learning and reasoning. Artificial Intelligence, 285, 103348.

[44] Besold, T. R., Garcez, A. d'Avila, Bader, S., Bowman, H., Domingos, P., Hitzler, P., Kühnberger, K.-U., Lamb, L. C., Lowd, D., Lima, P. M. V., et al. (2020). Neural-symbolic learning and reasoning: A survey and interpretation. IEEE Transactions on Neural Networks and Learning Systems, 31(1), 1–19.

[45] Rai, A. (2020). Explainable AI: From black box to glass box. Journal of the Academy of Marketing Science, 48, 137–141.

[46] Arrieta, A. B., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., García, S., Gil-Lopez, S., Molina, D., Benjamins, R., et al. (2020). Explainable artificial intelligence (XAI): Concepts, taxonomies, opportunities and challenges. Information Fusion, 58, 82–115.

[47] Gunning, D., & Aha, D. (2021). DARPA's explainable artificial intelligence (XAI) program. AI Magazine, 42(2), 44–58.

[48] European Commission. (2021). Proposal for a regulation laying down harmonised rules on artificial intelligence (Artificial Intelligence Act). Official Journal of the European Union.

[49] Floridi, L., & Cowls, J. (2021). A unified framework of five principles for AI in society. Harvard Data Science Review, 3(1).

[50] Doshi-Velez, F., & Kim, B. (2020). Towards a rigorous science of interpretable machine learning. ACM Computing Surveys, 52(5), 1–42.

[51] Rudin, C. (2021). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. Nature Machine Intelligence, 1–3.

[52] Mittelstadt, B. (2021). Principles alone cannot guarantee ethical AI. Nature Machine Intelligence, 3, 746–748.

[53] Zhou, J., Gandomi, A. H., Chen, F., & Holzinger, A. (2021). Evaluating the quality of machine learning explanations: A survey on methods and metrics. IEEE Transactions on Neural Networks and Learning Systems, 32(5), 1–21.

[54] Jordan, M. I., & Mitchell, T. M. (2020). Machine learning: Trends, perspectives, and prospects. Science, 349(6245), 255–260.

[55] Holzinger, A., et al. (2021). What do we need to build explainable AI systems for the medical domain? IEEE Computer, 54(10), 20–30.